

БУТКЕМП · КЕЙС М.ВИДЕО · NLP / SEARCH

Roadmap

от теории к standalone-поисковику

Сначала читаем и договариваемся, о чём задача. К середине буткемпа — EDA и живой MVP. Дальше своя разметка, жёстче факты, поиск по эмбедингам и упаковка под защиту.

ПРИНЦИП

Факты из запроса должны помочь найти SKU, а не просто красиво лежать в JSON.

СРОКИ

EDA + MVP к дню 2–3. Параллельно кошим свою разметку и не врём себе на метриках.

Как это читать

План кривоватый по нагрузке — так и задумано. В начале теория, в середине инженерия, ближе к защите — продукт и история для стейкхолдеров.



под «2 EDA+MVP» — жёсткий чекпоинт

1. День 0 — до буткемпа: просто понять язык

Пока никто не кодит ради скрина. Читаем и договариваемся, что значат слова.

00 Теория и насмотренность

ЧТО ДЕЛАЕМ

1. Лонгриды и семинары: признаки, overfitting, train/test, метрики.
2. NLP: токены, BIO, чем NER отличается от классификации всего запроса.
3. CRF vs «сразу нейросеть»: когда хватает модели на признаках токена.
4. Эмбединги и косинус — задел под поиск, не обязательно в день 1.
5. Трансформеры понимать ок, но тяжёлый BERT в MVP под SLA < 100 мс не тащим.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Общий язык: факт, SKU, weak label, entity F1, latency.
2. Короткий конспект: что прочитали и что берём в кейс.

Читать: лонгриды курса, последовательности / attention, TF-IDF, P/R/F1.

2. День 01 — Погружение, но сразу лезем в данные

День не заканчивается планом на доске. К вечеру parquet уже открыт.

01 Синхронизация + репо + первый взгляд

ЧТО ДЕЛАЕМ

1. Сверить кейс: запрос → JSON с фактами, быстрее 100 мс.
2. Роли набросать (данные, модель, сервис/UI, доки).
3. Зафиксировать JSON: brand, category, attributes, entities, latency_ms.
4. Репозиторий, сырые гигабайты в gitignore, черновик README.
5. Открыть query_clicks и sku_desc: схемы, размеры, штук 20 строк.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Этот roadmap — план на дни 2–5.
2. Ноутбук overview: колонки, объёмы.

3. День 02 — Сюда нельзя опоздать: EDA + MVP

Если к вечеру нет JSON — на день 3 не прыгаем в приложение мечты.

02 EDA, словари, CRF, тонкий сервис

ЧТО ДЕЛАЕМ

1. EDA: топы, цена vs позиция, heatmaps — картинки в figures/.
2. Словари брендов и категорий → artifacts/*.txt.
3. Правила на ATTR + авто-БИО.
4. CRF: максимизируем $P(y | x)$; y — теги, x — слова запроса.
5. /extract (+ debug), чтобы любой вбил запрос и увидел JSON.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. EDA закрыт: ноутбуки + графики.
2. MVP жив: запрос → факты, latency в SLA.
3. Честно: метрики пока против weak labels, не против gold.

Gate дня 2. Нет JSON к вечеру — эмбединги подождут.
Сначала факты, потом красоты.

4. День 03 — Своя разметка и шесть ударов по качеству

Перестаём слепо верить словарю и начинаем мерить правду.

03 Gold / синтетика / переобучение

ЧТО ДЕЛАЕМ

1. Руками разметить пачку запросов (лучше сотни). Span + тип.
2. Чуть синтетики: «категория бренд attr» + шум.
3. Прогнать CRF по gold — честный F1.
4. Закрыть шесть пунктов ниже хотя бы в v1.
5. Переобучить на смеси weak + gold.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Gold-файл в репо + скрипт оценки.
2. Табличка «было / стало» по косякам.

Шесть пунктов — backlog, не мечты в стол

1. Факты точнее — меньше мусора в фильтрах.
2. Бренд и модель не путаем.
3. Нормализация: айфон / iphone / Apple → один канон.
4. Устойчивость к шуму: опечатки, регистр, 16гб.
5. Своя разметка + синтетика — честные метрики.
6. Score пары query↔click без сказки про 100% идеал.

5. День 04 — Standalone: NER внизу, поиск сверху

Эмбединги не вместо NER. Вместе.

04 Приложение + поиск по каталогу

ЧТО ДЕЛАЕМ

1. UI: поиск, подсветка сущностей, JSON, latency vs 100 мс.
2. Индекс по sku_desc. На старте ок TF-IDF+SVD.
3. Гибрид: буст по фактам NER + близость запрос-SKU.
4. 5–10 выдач «до / после» — лучший слайд защиты.
5. Заготовка high-score пар query-click.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Демо: запрос → факты + топ SKU.
2. Схема: query → NER → facts → retrieve → SKU.



6. День 05 — Упаковка и защита

05 История для людей, не только git log

ЧТО ДЕЛАЕМ

1. Питч: проблема → факты → метрики → демо → дальше.
2. Сценарии: категория, бренд+ATTR, грязный запрос.
3. Ретро без понтов: что срезали и где клики ввали.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Защита с живым демо и честной зоной роста.
2. After: dual-encoder, больше gold, когда-нибудь A/B.

7. Кто за что

Зона	Фокус
Данные / EDA	parquet, графики, словари, score query-click
NER / метрики	BIO, CRF, gold, F1, нормализация
Поиск / апп	UI, индекс, эмбединги, гибридная выдача
Доки / питч	LaTeX, README, слайды

8. Чего сознательно не делаем

1. Не тащим огромный LLM в runtime, если он убивает SLA.
2. Не рисуем 40 графиков вместо gold на день 3.
3. Не обещаем идеальный поиск М.Видео за неделю — обещаем контур факты→выдача.

Если день 2 горит — режем эмбединги до TF-IDF.
JSON-MVP и честность про метрики не режем.