

БУТКЕМП · КЕЙС М.ВИДЕО · NLP / SEARCH

Дорожная карта

от теории к собственному поисковику

Сначала читаем и договариваемся, о чём задача. К середине буткемпа — разведка данных и живая первая версия. Дальше своя разметка, жёстче факты, поиск по эмбедингам и упаковка под защиту.

Если совсем коротко: задача — вытащить из текста нормализованные атрибуты (бренд, модель, цвет, память, диагональ...) и не сломать этим поиск. Смотрим с двух сторон: из *запроса* пользователя и из *карточки* товара. Каждый атрибут отдаём не голым значением, а как «значение + уверенность», чтобы потом можно было ставить пороги и не тащить в фильтры мусор.

ПРИНЦИП

Факты из запроса должны помогать найти товар, а не просто красиво лежать в JSON.

СРОКИ

Разведка данных + первая версия к дню 2–3. Параллельно копим свою разметку и не врём себе на метриках.

Как это читать

План кривоватый по нагрузке — так и задумано. В начале теория, в середине инженерия, ближе к защите — продукт и история для тех, кто принимает решения.



на дне 2 — жёсткая контрольная точка

1. День 0 — до буткемпа: просто понять язык

Пока никто не кодит ради скрина. Читаем и договариваемся, что значат слова.

00 Теория и насмотренность

ЧТО ДЕЛАЕМ

1. Лонгриды и семинары: признаки, переобучение, обучающая и тестовая выборки, метрики.
2. Работа с текстом: токены, BIO-разметка, чем извлечение сущностей отличается от классификации всего запроса.
3. CRF против «сразу нейросеть»: когда хватает модели на признаках токена.
4. Эмбединги и косинусная близость — задел под поиск, не обязательно в день 1.
5. Трансформеры понимать полезно, но тяжёлый BERT в первую версию под ограничение < 100 мс не тащим. При этом дистиллированный или обрезанный энкодер держим в голове как запасной вариант на хвост — если скорость позволит.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Общий язык: факт, товар, слабая разметка, качество по сущностям, время ответа.
2. Короткий конспект: что прочитали и что берём в кейс.

Читать: лонгриды курса, последовательности и механизм внимания, TF-IDF, точность / полнота /

F1.

2. День 01 — Погружение, но сразу лезем в данные

День не заканчивается планом на доске. К вечеру parquet уже открыт.

01 Синхронизация + репозиторий + первый взгляд

ЧТО ДЕЛАЕМ

1. Сверить кейс: запрос → JSON с фактами, быстрее 100 мс.
2. Набросать роли (данные, модель, сервис и интерфейс, документация).
3. Зафиксировать формат ответа: бренд, категория, атрибуты (значение + уверенность), сущности, время ответа.
4. Репозиторий, сырые гигабайты не коммитим, черновик инструкции по запуску.
5. Открыть таблицы запросов-кликов и описаний товаров: схемы, размеры, штук 20 строк глазами.
6. Не верить, что «данные пришли как надо»: распаковать каталог из пикла и проверить структуру, кодировку, обязательные поля.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Эта дорожная карта — план на дни 2–5.
2. Обзорный ноутбук: какие колонки, какие объёмы.

ПРОВЕРКА ДАННЫХ — УЖЕ СДЕЛАЛИ

Каталог живой: 1.5 ГБ, распаковался, внутри **546 069 товаров**, кириллица читается без кракозябр, название, производитель, модель и атрибуты заполнены на 100%. То есть по тексту данные пришли нормально, паниковать не о чем.

Но есть подвох: картинок в выгрузке **нет вообще** — поле с фото пустое у всех товаров. Так что идея «брать цвет с фото» — это отдельный поход за картинками по номеру или ссылке товара, а не поле из коробки. Цвет как текстовый атрибут есть примерно у двух третей, у хвоста — пусто, вот там фото и пригодится.

3. День 02 — Сюда нельзя опоздать: данные + первая версия

Если к вечеру нет JSON — на день 3 не прыгаем в приложение мечты.

02 Разведка данных, словари, регулярки, CRF, тонкий сервис

ЧТО ДЕЛАЕМ

1. Разведка данных: топы запросов и брендов, цена против позиции, тепловые карты — картинки в папку с графиками.
2. Словари брендов и категорий — в текстовые файлы-артефакты.
3. Регулярные выражения на атрибуты (объём памяти, диагональ, цвет, «16гб» и прочее) + автоматическая BIO-разметка по словарям. Это ядро нормализации: дёшево, предсказуемо и мгновенно по скорости.
4. CRF: максимизируем $P(y | x)$; y — теги, x — слова запроса.
5. Ручка извлечения (+ отладочная), чтобы любой вбил запрос и увидел JSON.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Разведка данных закрыта: ноутбуки + графики.
2. Первая версия живая: запрос → факты, время ответа в пределах 100 мс.
3. Честно: метрики пока против слабой разметки, не против эталона.

Gate дня 2. Нет JSON к вечеру — эмбединги подождут.
Сначала факты, потом красоты.

4. День 03 — Своя разметка и шесть ударов по качеству

Перестаем слепо верить словарю и начинаем мерить правду.

03 Эталонная разметка / синтетика / переобучение

ЧТО ДЕЛАЕМ

1. Руками разметить пачку запросов (лучше сотни): границы сущности + тип.
2. Чуть синтетики: «категория бренд атрибут» + шум.
3. Прогнать CRF по эталону: точность, полнота и $F1$ по каждому атрибуту + покрытие, а не одна средняя цифра (она прячет провал на редких значениях).
4. Закрыть шесть пунктов ниже хотя бы в первой версии.
5. Переобучить на смеси слабой и эталонной разметки.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Файл эталонной разметки в репозитории + скрипт оценки.
2. Табличка «было / стало» по косякам.
3. Метрики честные: по атрибутам, важные поля взвешены по трафику (по которым реально фильтруют).

Шесть пунктов — рабочий список, не мечты в стол

1. Факты точнее — меньше мусора в фильтрах.

2. Бренд и модель не путаем.
3. Нормализация и снятие неоднозначности: айфон / iphone / Apple → один канон. Первый слой — регулярки и словари синонимов (быстро и предсказуемо), второй — контекст: «красный» — это цвет, а «Красный Октябрь» — уже бренд, и что имелось в виду, решает окружение слова, а не словарь в лоб.
4. Устойчивость к шуму: опечатки, регистр, «16гб» слитно.
5. Своя разметка + синтетика — честные метрики.
6. Скоринг пары запрос↔клик без сказки про стопроцентный идеал.

5. День 04 — Своё приложение: извлечение внизу, поиск сверху

Эмбединги не вместо извлечения фактов. Вместе.

04 Приложение + поиск по каталогу

ЧТО ДЕЛАЕМ

1. Интерфейс: строка поиска, подсветка сущностей, JSON, время ответа против планки 100 мс.
2. Индекс по описаниям товаров. На старте достаточно TF-IDF со сжатием размерности.
3. Гибрид: усиление по извлечённым фактам + близость запроса и товара.
4. 5–10 выдач «до / после» — лучший слайд защиты.
5. Заготовка пар запрос–клик с высокой уверенностью.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Демо: запрос → факты + подборка товаров.
2. Схема: запрос → извлечение → факты → поиск → товары.



6. День 05 — Упаковка и защита

05 История для людей, не только история коммитов

ЧТО ДЕЛАЕМ

1. Питч: проблема → факты → метрики → демо → что дальше.
2. Сценарии: категория, бренд + атрибут, грязный запрос с опечатками.
3. Ретроспектива без понтов: что срезали и где клики ввали.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Защита с живым демо и честной зоной роста.
2. На потом: двухбашенный энкодер, больше эталонной разметки, когда-нибудь честный эксперимент на трафике.

7. Сравнение подходов — тот самый «решающий» слайд

На защите первым делом спросят: «почему так, а не нейросеткой всё подряд / не большой языковой моделью на всё». Ответ — вот эта табличка. Смысл простой: ни один подход не закрывает все колонки сразу, поэтому в бою они уживаются вместе, а не воюют.

Подход	Хвост	Цена	Данные	Поддержка	Новые категории
Правила (регулярки + словари)	низко	очень низко	не нужны	средне	хорошо
Извлечение на CRF	средне	низко	средне	средне	слабо
Трансформер (BERT)	высоко	средне	много	средне	слабо
Текст + фото	высоко	высоко	много	сложно	слабо
Языковая модель с примерами	высоко	высоко	мало	легко	отлично

«Цена» — стоимость обработки одного запроса; «Хвост» — качество на редких значениях; «Данные» — сколько разметки нужно.

Вывод: правильного «одного» подхода нет. Гибрид: правила и словари держат ядро и дают дешёвый ориентир, обученная модель (CRF, дальше — трансформер) добывает свободный текст и хвост, языковая модель затыкает холодный старт и совсем редкие категории. Мы честно показываем этот компромисс «покрытие ↔ стоимость ↔ поддерживаемость», а не делаем вид, что «взяли самое модное и всё заработало».

Каскад по скорости: тяжёлое — только когда лёгкое не справилось

Главное требование — скорость, поэтому конвейер строим каскадом, а не «одна большая модель на всё»:

1. **Первый эшелон** — регулярки и словари. Отвечают мгновенно и закрывают большинство типовых запросов.
2. **Второй эшелон** — CRF. Считанные миллисекунды, добывает свободный текст и неожиданные формулировки.
3. **Третий эшелон, запасной** — дистиллированный трансформер или локальная языковая модель-агент с контекстом (справочники значений, похожие карточки, история категории). Зовём его *только* когда лёгкие слои не уверены, и только там, где укладываемся по времени: онлайн — с жёстким лимитом, офлайн (разбор каталога, предразметка) — без спешки.
4. Решение «звать или не звать тяжёлый слой» принимает порог уверенности — тот самый, ради которого каждый атрибут несёт с собой оценку уверенности.

Так планка «быстрее 100 мс» держится на типовых запросах, а качество на хвосте не приносится в жертву — оно просто стоит дороже и включается точно.

8. Растяжки — если останется время (и на потом)

Это не обязалово на неделю, а честный список «куда дальше». На защите показать как понимание продукта, а не как невыполненный план.

+ Картинка как второй источник правды

ЧТО ДЕЛАЕМ

1. По номеру или ссылке товара подтянуть фото с М.Видео (в выгрузке каталога картинок нет — надо ходить наружу).
2. Визуальный энкодер (SigLIP / CLIP) → достаём цвет, дальше — принт и форму.
3. Сверять с текстом: описание про цвет молчит — берём с фото; текст и фото спорят — флаг на ручную проверку.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Добор покрытия по цвету на хвосте, где текстовый атрибут пустой.
2. Понимание, где картинка реально нужна, а где это пальба из пушки по воробьям.

+ Языковая модель на холодный старт и длинный хвост

ЧТО ДЕЛАЕМ

1. Новая категория без разметки → запрос с примерами и **жёсткой схемой ответа** (JSON строго по шаблону).
2. Загон в рамки: значения только из справочника, порог уверенности, проверка «откуда взяли значение» — иначе выдумки модели ломают фильтры.
3. Разметка с помощником: модель пред-размечает, человек только проверяет — дешёвые метки, которыми потом кормим свою быструю модель.
4. Локальный агент с контекстом (справочники, похожие карточки) — как запасной слой для офлайн-разбора каталога, где нет ограничения по времени.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Ответ на «а как вы заводите новую категорию за день, а не за месяц».
2. Страховка от выдумок модели описана заранее, а не постфактум на вопрос из зала.

9. Риски — называем сами, раньше, чем спросят

На взрослом ревью первым делом спрашивают про риски. Прятать их — худшая стратегия; показываем сразу с мерой снижения.

1. **Выдумки языковой модели** → ложные атрибуты ломают фильтры. Лечим жёсткой схемой ответа + порогом уверенности.
2. **Цена на масштабе** → языковая модель на каждый из 546 тысяч товаров — дорого. Лечим каскадом: тяжёлый слой только на хвост и холодный старт.
3. **Оценка врёт** → красивая средняя метрика прячет провал на редких категориях. Лечим эталонной разметкой по хвосту и метриками по атрибутам.
4. **Дрейф** → новые товары и категории каждый день. Нужны мониторинг и петля дообучения.
5. **Несправедливость к мелким продавцам** → их карточки беднее, извлекаются хуже. Следим за покрытием по сегментам.

10. Кто за что

Зона	Фокус
Данные / разведка	выгрузки, графики, словари, скоринг пар запрос–клик
Извлечение / метрики	BIO-разметка, CRF, эталон, качество по атрибутам, нормализация
Поиск / приложение	интерфейс, индекс, эмбединги, гибридная выдача
Документы / питч	вёрстка, инструкция по запуску, слайды

11. Чего сознательно не делаем

-
1. Не тащим огромную языковую модель в обработку каждого запроса, если она убивает планку по скорости. Как запасной слой на редких случаях — можно, как основной путь — нет.
 2. Не рисуем 40 графиков вместо эталонной разметки на день 3.
 3. Не обещаем идеальный поиск М.Видео за неделю — обещаем работающий контур «факты → выдача».

Если день 2 горит — режем эмбединги до простого TF-IDF.
Живой JSON и честность про метрики не режем.

Вся дорожная карта на одной странице

запрос → факты (значение + уверенность) → выдача товаров · быстрее 100 мс · без вранья на метриках

0 · ТЕОРИЯ

Договариваемся о словах: BIO-разметка, CRF, эмбединги, метрики.

Тяжёлые модели понимаем, но в быструю версию не тащим.

Итог: общий язык + конспект.

1 · КАРКАС

Репозиторий, роли, формат ответа: бренд, категория, атрибуты + уверенность.

Проверка данных: каталог распакован, 546 тыс. товаров, текст цел, **фото нет**.

Итог: план + обзорный ноутбук.

2 · ДАННЫЕ + ВЕРСИЯ

Разведка: топы, цены, тепловые карты.

Словари + **регулярки** на атрибуты, авто-BIO, CRF, тонкий сервис с ручкой извлечения.

Контрольная точка: к вечеру живой JSON быстрее 100 мс.

3 · РАЗМЕТКА

Эталон руками (сотни запросов) + синтетика.

Метрики по каждому атрибуту, не одна средняя. Нормализация: айфон/iphone → канон; «красный» — цвет, «Красный Октябрь» — бренд.

Итог: честный эталон + «было/стало».

4 · ПОИСК

Интерфейс: подсветка сущностей, JSON, время ответа.

Индекс по каталогу, гибрид: факты + близость запроса и товара.

Итог: демо «запрос → товары» + слайд «до/после».


5 · ЗАЩИТА

Питч: проблема → факты → метрики → демо → дальше.

Сценарии: категория, бренд + атрибут, грязный запрос. Ретроспектива без понтов.

Итог: живое демо + честная зона роста.

КАСКАД ПО СКОРОСТИ — ТЯЖЁЛОЕ ТОЛЬКО КОГДА ЛЁГКОЕ НЕ СПРАВИЛОСЬ



ГИБРИД ПОДХОДОВ — КТО ЗА ЧТО

Правила и регулярки — ядро: дёшево, предсказуемо, легко чинить.

CRF — свободный текст и неожиданные формулировки.

Трансформер — качество на хвосте, когда позволит скорость.

Фото (SigLIP/CLIP) — цвет и узор там, где текст молчит.

Языковая модель — новые категории и предразметка, строго по схеме и справочникам.

Одного правильного подхода нет — есть разделение труда.

РИСКИ И ЛЕКАРСТВА

Выдумки модели → жёсткая схема + порог уверенности.

Дорого на 546 тыс. товаров → каскад, тяжёлое только на хвост.

Оценка врёт → эталон по редким категориям, метрики по атрибутам.

Дрейф → мониторинг + петля дообучения.

Мелкие продавцы хуже извлекаются → следим за покрытием по сегментам.

РАСТЯЖКИ И ГРАНИЦЫ

Если успеем: фото товара как второй источник правды (цвет, узор); разметка с моделью-помощником; двухбашенный энкодер для поиска.

Сознательно не делаем: тяжёлую модель в каждом запросе; 40 графиков вместо эталона; обещаний идеального поиска за неделю.

Если горит — режем эмбединги. JSON и честность не режем.

Принцип всей недели: факты из запроса должны **находить товар**, а не просто красиво лежать в JSON.