

Roadmap

от теории к standalone-поисковику

Не «пять одинаковых колонок из методички», а рабочий план команды: сначала читаем и договариваемся о языке задачи, к середине буткемпа уже есть EDA + живой MVP, дальше — своя разметка, жёстче факты, эмбединговый поиск и упаковка под защиту.

ПРИНЦИП

Факты из запроса должны помогать найти SKU, не просто красиво выглядеть в JSON.

СЖАТЫЙ СРОК

EDA + MVP — к дню 2–3. Параллельно копим свою разметку и не врем себе метриками.

Как читать этот план

План специально **неровный**: в начале больше теории и синхронизации, в середине — плотная инженерия, ближе к защите — продукт и история для стейкхолдеров.



1. День 0 — до буткемпа: язык задачи

Пока нет «вайбкодинга ради скрина». Есть чтение и общий словарь.

00 Теория и насмотренность

делаем

- Лонгриды / семинары по классическому ML и последовательностям: признаки, overfitting, train/test, метрики.
- NLP-база: токенизация, BIO, чем NER отличается от классификации всего запроса целиком.
- CRF vs «просто нейросеть»: когда хватает линейной модели на признаках токена.
- Word2Vec / эмбединги / косинус — задел под поиск по пространству, не обязательно внедрять в день 1.
- Трансформеры — понимать идею; в MVP не тащить тяжёлый BERT, если SLA < 100 мс на CPU.

на выходе

- Общий язык: *факт, SKU, weak label, entity F1, latency*.
- Короткий конспект «что читали / что берём в кейс» (1–2 страницы на команду).

Черновой стек чтения (подставить свои источники): курсные лонгриды по ИИ, блок про RNN/attention/трансф, заметки по TF-IDF и метрикам $P/R/F1$.

2. День 01 — Погружение → сразу в данные

Не заканчиваем день только «роадмапом на доске». К вечеру уже трогаем parquet.

01 Синхронизация + скелет репо + первый взгляд на данные

делаем

- Сверить понимание кейса: запрос → JSON-факты < 100 мс; конверсия через релевантность.
- Роли: данные/EDA, модель/NER, сервис/UI, доки/защита — но без жёстких стен, все смотрят метрики.
- Зафиксировать целевой JSON: `brand, category, attributes, entities, latency_ms`.
- Поднять репозиторий, `.gitignore` на сырые гигабайты, черновик README.
- Открыть `query_clicks / sku_desc`: схемы, объёмы, 20 сырых примеров в ноутбук.

на выходе

- Утверждённый мини-план на дни 2–5 (этот документ).
- Ноутбук `01_overview`: размеры, колонки, 0 «магии» в данных.

3. День 02 — Чекпоинт: EDA готов, MVP дышит

Это день, к которому нельзя опоздать. Если сюда не дошли — режем скоуп, не расползаемся в «красивый рефакторинг».

02 EDA + weak labels + первый CRF + тонкий сервис

делаем

- EDA: длины запросов, топ-бренды/запросы, цена vs позиция, co-occurrence, TF-IDF heatmaps — пачка графиков в `figures/`.
- Словари из кликов: бренды / категориальные фразы → `artifacts/*.txt`.
- Правила ATTR (память, цвет, диагональ...) + BIO-авторазметка.
- Обучить CRF (`sklearn-crfsuite`): $P(y | x)$, holdout на авто-тегах, entity F1 / token Acc.
- Поднять `/extract` (и `debug`), чтобы любой из команды вбивал запрос и видел JSON.

на выходе

- **EDA-пакет закрыт** (ноутбуки + ≥ 10 графиков).
- **MVP-ядро**: запрос → факты JSON, p95 latency заметно ниже 100 мс.
- Честный дисклеймер в доке: метрики пока против weak labels, не против ручного gold.

Gate: нет JSON-сервиса к концу дня 2 — на день 3 не начинаем «приложение мечты», сначала дожимаем извлечение фактов.

4. День 03 — Своя разметка и шесть ударов по качеству фактов

Здесь команда перестаёт «верить словарю» и начинает мерить правду.

03 Gold / synthetic + точность фактов

делаем

- Ручная разметка выборки запросов (цель: сотни, не «три примера»). Формат: `span + тип`.
- Чуть синтетики: шаблоны `{category} {brand} {attr}` + шум/опечатки.
- Прогнать текущий CRF по gold: честный entity F1 — это новая правда.
- Дожать шесть направлений (ниже) хотя бы на уровне v1.
- Дообучить / переобучить CRF (и при необходимости правила) на смеси weak + gold.

на выходе

- Файл gold-разметки в репо + скрипт оценки на нём.
- Короткая таблица «было / стало» по ошибкам: бренд ↔ модель, нормализация, ATTR.

Шесть пунктов — не wishlist, а backlog дня 3

1. **Факты точнее** — меньше мусора, чтобы фильтры поиска не ввали.
2. **Бренд ≠ модель** — `iphone/galaxy s25` не обязаны быть vendor-строкой один-в-один.
3. **Нормализация** — `айфон/iphone/Apple` сходятся к канону.

4. **Устойчивость к шуму** — опечатки, регистр, склейки 16гб.
5. **Своя разметка + синтетика** — честные метрики, не только self-check словаря.
6. **Query↔click score** — правила «согласованной пары» (бренд совпал, токены в title, позиция клика); отбор clean-пар под следующую модель, не «100% идеал».

5. День 04 — Standalone: NER в фундаменте, сверху поиск

Не заменяем NER эмбедингами. Склеиваем.


04 Приложение + эмбединговый поиск по каталогу

делаем

- UI/лаба: ввод запроса, подсветка сущностей, JSON, latency vs SLA (уже можно усилить до «поиска»).
- Индекс по sku_desc / сэмплу каталога: эмбединги title (TF-IDF+SVD на старте; sentence-embeddings — если влезает по времени/CPU).
- Ранжирование-гибрид: (a) фильтры/буст по фактам NER, (b) косинус в пространстве запрос-SKU.
- Показать 5–10 выдач «до/после» фактов — это лучший слайд защиты.
- Заготовка под пункт 6: таблица high-score пар query-click для будущего дообучения.

на выходе

- Standalone-демо: строка поиска → факты + топ SKU.
- Понятная схема на один слайд: query $\xrightarrow{\text{NER}}$ facts $\xrightarrow{\text{retrieve}}$ SKU.



6. День 05 — Упаковка и защита

05 История для людей, не только для git log

делаем

- Собрать питч: проблема → факты → метрики (weak vs gold) → демо UI/поиска → что дальше.
- Прогнать сценарии: категоричный запрос, бренд+ATTR, грязный запрос, провал модели — и что с ним делать.
- Ретро: что срезали, что переоценили, где клики ввали.

на выходе

- Защита пройдена с живым демо и честной зоной роста.
- Roadmap «после буткемпа»: нормальный dual-encoder, больше gold, A/B на выдаче.

7. Кто за что отвечает (живой вариант)

Зона	Фокус
Данные / EDA	parquet, графики, словари, score query-click
NER / метрики	BIO, CRF, gold-разметка, F1, нормализация
Поиск / app	UI, индекс, эмбединги, гибридная выдача
Доки / питч	LaTeX, README, слайды, «что сказать за 5 минут»

8. Анти-цели (чтобы не умереть)

- Не тащить огромный LLM в runtime ради демо, если убиваем SLA.
- Не рисовать 40 графиков вместо gold-разметки на день 3.
- Не обещать «идеальный поиск М.Видео за неделю» — обещаем **работающий контур** факты→выдача и понятный next step.

План живой: если день 2 горит — режем эмбединги до TF-IDF, но не режем JSON-MVP и честность про метрики.