

БУТКЕМП · КЕЙС М.ВИДЕО · NLP / SEARCH

Roadmap

от теории к standalone-поисковику

Сначала читаем и договариваемся, о чём задача. К середине буткемпа — EDA и живой MVP. Дальше своя разметка, жёстче факты, поиск по эмбедингам и упаковка под защиту.

Если совсем коротко: задача — вытащить из текста нормализованные атрибуты (бренд, модель, цвет, память, диагональ...) и не сломать этим поиск. Смотрим с двух сторон: из *запроса* пользователя и из *карточки* товара. Каждый атрибут отдаём не голым значением, а как «значение + уверенность», чтобы потом можно было ставить пороги и не тащить в фильтры мусор.

ПРИНЦИП

Факты из запроса должны помогать найти SKU, а не просто красиво лежать в JSON.

СРОКИ

EDA + MVP к дню 2–3. Параллельно копим свою разметку и не врем себе на метриках.

Как это читать

План кривоватый по нагрузке — так и задумано. В начале теория, в середине инженерия, ближе к защите — продукт и история для стейкхолдеров.

0 теория ➤ 1 каркас ➤ 2 EDA+MVP ➤ 3 разметка ➤ 4 поиск ➤ 5 защита

под «2 EDA+MVP» — жёсткий чекпоинт

1. День 0 — до буткемпа: просто понять язык

Пока никто не кодит ради скрина. Читаем и договариваемся, что значат слова.

00 Теория и насмотренность

ЧТО ДЕЛАЕМ

1. Лонгриды и семинары: признаки, overfitting, train/test, метрики.
2. NLP: токены, BIO, чем NER отличается от классификации всего запроса.
3. CRF vs «сразу нейросеть»: когда хватает модели на признаках токена.
4. Эмбединги и косинус — задел под поиск, не обязательно в день 1.
5. Трансформеры понимать ок, но тяжёлый BERT в MVP под SLA < 100 мс не тащим.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Общий язык: факт, SKU, weak label, entity F1, latency.
2. Короткий конспект: что прочитали и что берём в кейс.

Читать: лонгриды курса, последовательности / attention, TF-IDF, P/R/F1.

2. День 01 — Погружение, но сразу лезем в данные

День не заканчивается планом на доске. К вечеру parquet уже открыт.

01 Синхронизация + репо + первый взгляд

ЧТО ДЕЛАЕМ

1. Сверить кейс: запрос → JSON с фактами, быстрее 100 мс.
2. Роли набросать (данные, модель, сервис/UI, доки).
3. Зафиксировать JSON: brand, category, attributes (значение + уверенность), entities, latency_ms.
4. Репозиторий, сырые гигабайты в gitignore, черновик README.
5. Открыть query_clicks и sku_desc: схемы, размеры, штук 20 строк.
6. Не верить, что «данные пришли как надо»: распаковать skus.pkl и проверить структуру, кодировку, обязательные поля.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Этот roadmap — план на дни 2–5.
2. Ноутбук overview: колонки, объёмы.

ПРОВЕРКА ДАННЫХ — УЖЕ СДЕЛАЛИ

skus.pkl живой: 1.5 ГБ, распаковался, внутри **546 069 офферов**, кириллица читается без кракозябр, поля *name* / *vendor* / *model* / *param* заполнены на 100%. То есть по тексту данные пришли нормально, паниковать не о чем.

Но есть подвох: картинок в пикле **нет вообще** — поле *picture* пустое у всех офферов. Так что идея «брать цвет с фото» — это отдельный поход за картинками по id/url М.Видео, а не поле из коробки. Цвет как текстовый атрибут (*Цвет_search*) есть примерно у 2/3, у хвоста — пусто, вот там фото и пригодится.

3. День 02 — Сюда нельзя опоздать: EDA + MVP

Если к вечеру нет JSON — на день 3 не прыгаем в приложение мечты.

02 EDA, словари, CRF, тонкий сервис

ЧТО ДЕЛАЕМ

1. EDA: топы, цена vs позиция, heatmaps — картинки в figures/.
2. Словари брендов и категорий → artifacts/*.txt.
3. Правила на ATTR + авто-BIO.
4. CRF: максимизируем $P(y | x)$; y — теги, x — слова запроса.
5. /extract (+ debug), чтобы любой вбил запрос и увидел JSON.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. EDA закрыт: ноутбуки + графики.
2. MVP жив: запрос → факты, latency в SLA.
3. Честно: метрики пока против weak labels, не против gold.

Gate дня 2. Нет JSON к вечеру — эмбединги подождут.
Сначала факты, потом красоты.

4. День 03 — Своя разметка и шесть ударов по качеству

Перестаем слепо верить словарю и начинаем мерить правду.

03 Gold / синтетика / переобучение

ЧТО ДЕЛАЕМ

1. Руками разметить пачку запросов (лучше сотни). Span + тип.
2. Чуть синтетики: «категория бренд attr» + шум.
3. Прогнать CRF по gold: P/R/F1 *по каждому атрибуту* + coverage, а не одну среднюю ассурасу (она прячет провал на хвосте).
4. Закрыть шесть пунктов ниже хотя бы в v1.
5. Переобучить на смеси weak + gold.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Gold-файл в репо + скрипт оценки.
2. Табличка «было / стало» по косякам.
3. Метрики честные: по атрибутам, важные поля взвешены по трафику (по которым реально фильтруют).

Шесть пунктов — backlog, не мечты в стол

1. Факты точнее — меньше мусора в фильтрах.
2. Бренд и модель не путаем.
3. Нормализация и снятие неоднозначности: айфон / iphone / Apple → один канон; «красный» — это

цвет, а «Красный Октябрь» — уже бренд, и что именно имелось в виду, решает контекст, а не словарь в лоб.

4. Устойчивость к шуму: опечатки, регистр, 16гб.
5. Своя разметка + синтетика — честные метрики.
6. Score пары query↔click без сказки про 100% идеал.

5. День 04 — Standalone: NER внизу, поиск сверху

Эмбединги не вместо NER. Вместе.

04 Приложение + поиск по каталогу

ЧТО ДЕЛАЕМ

1. UI: поиск, подсветка сущностей, JSON, latency vs 100 мс.
2. Индекс по sku_desc. На старте ок TF-IDF+SVD.
3. Гибрид: буст по фактам NER + близость запрос-SKU.
4. 5–10 выдач «до / после» — лучший слайд защиты.
5. Заготовка high-score пар query-click.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Демо: запрос → факты + топ SKU.
2. Схема: query → NER → facts → retrieve → SKU.



6. День 05 — Упаковка и защита

05 История для людей, не только git log

ЧТО ДЕЛАЕМ

1. Питч: проблема → факты → метрики → демо → дальше.
2. Сценарии: категория, бренд+ATTR, грязный запрос.
3. Ретро без понтов: что срезали и где клики ввали.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Защита с живым демо и честной зоной роста.
2. After: dual-encoder, больше gold, когда-нибудь A/B.

7. Сравнение подходов — тот самый «решающий» слайд

На защите первым делом спросят: «почему так, а не нейросеткой всё подряд / не LLM на всё». Ответ — вот эта табличка. Смысл простой: ни один подход не закрывает все колонки сразу, поэтому в проде они уживаются вместе, а не воюют.

Подход	Хвост	Цена	Данные	Поддержка	Cold-start
Правила (regex+словари)	низко	очень низко	не нужны	средне	высоко
NER / CRF	средне	низко	средне	средне	низко
Трансформер (BERT)	высоко	средне	много	средне	низко
Мультимодал (текст+фото)	высоко	высоко	много	низко	низко
LLM few-shot	высоко	высоко	мало	высоко	очень высоко

«Цена» — стоимость инференса; «Хвост» — качество на редких значениях; «Данные» — сколько разметки нужно.

Вывод: правильного «одного» подхода нет. Гибрид: правила и словари держат ядро и дают дешёвый бейзлайн, обученная модель (CRF, дальше — BERT) добывает свободный текст и хвост, LLM затыкает cold-start и совсем редкие категории. Мы честно показываем этот компромисс «покрытие ↔ стоимость ↔ поддерживаемость», а не делаем вид, что «взяли самое модное и всё заработало».

8. Растяжки — если останется время (и на *after*)

Это не обязалово на неделю, а честный список «куда дальше». На защите показать как понимание продукта, а не как невыполненный план.

+ Картинка как второй источник правды

ЧТО ДЕЛАЕМ

1. По id/url оффера подтянуть фото с М.Видео (в pickle картинок нет — надо ходить наружу).
2. Vision-энкодер (SigLIP / CLIP) → достаём цвет, дальше — принт и форму.
3. Сверять с текстом: описание про цвет молчит — берём с фото; текст и фото спорят — флаг на ручную проверку.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Добор покрытия по цвету на хвосте, где текстовый атрибут пустой.
2. Понимание, где мультимодалка реально нужна, а где это оверкилл ради оверкилла.

+ LLM на cold-start и длинный хвост

ЧТО ДЕЛАЕМ

1. Новая категория без разметки → few-shot промпт со **structured output** (JSON строго по схеме).
2. Загон в рамки: значения из справочника, порог уверенности, проверка «откуда взяли значение» — иначе галлюцинации ломают фильтры.
3. LLM-assisted разметка: модель пред-размечает, человек только верифицирует — дешёвые лейблы, которыми потом кормим свою модель.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Ответ на «а как вы заводите новую категорию за день, а не за месяц».
2. Страховка от галлюцинаций описана заранее, а не постфактум на вопрос из зала.

9. Риски — называем сами, раньше, чем спросят

На уровне «взрослого» ревью первым делом спрашивают про риски. Прятать их — худшая стратегия; показываем сразу с мерой снижения.

1. **Галлюцинации LLM** → ложные атрибуты ломают фильтры. Лечим structured output + порогом уверенности.
2. **Цена на масштабе** → LLM на каждый из 546k офферов — дорого. Лечим гибридом: LLM только на хвост и cold-start.
3. **Eval врёт** → красивая средняя метрика прячет провал на редких категориях. Лечим gold по хвосту и метриками по атрибутам.
4. **Дрейф** → новые SKU и категории каждый день. Нужны мониторинг и петля дообучения.
5. **Несправедливость к мелким продавцам** → их карточки беднее, извлекаются хуже. Следим за покрытием по сегментам.

10. Кто за что

Зона	Фокус
Данные / EDA	parquet, графики, словари, score query-click
NER / метрики	BIO, CRF, gold, F1, нормализация
Поиск / апп	UI, индекс, эмбединги, гибридная выдача
Доки / питч	LaTeX, README, слайды

11. Чего сознательно не делаем

1. Не тащим огромный LLM в runtime, если он убивает SLA.
2. Не рисуем 40 графиков вместо gold на день 3.
3. Не обещаем идеальный поиск М.Видео за неделю — обещаем контур факты→выдача.

Если день 2 горит — режим эмбединги до TF-IDF.
JSON-MVP и честность про метрики не режим.