

БУТКЕМП · КЕЙС М.ВИДЕО · NLP / SEARCH

Roadmap

от теории к standalone-поисковику

Нормальный план команды: сначала читаем и договариваемся, о чём вообще задача. К середине буткемпа уже есть EDA и живой MVP. Дальше — своя разметка, более жёсткие факты, поиск по эмбедингам и упаковка под защиту.

ПРИНЦИП

Факты из запроса должны помогать найти нужный SKU, а не просто красиво лежать в JSON.

СРОКИ

EDA + MVP — к дню 2–3. Параллельно копируем свою разметку и не врём себе на метриках.

Как это читать

План специально кривоватый по нагрузке — и это ок. В начале больше теории и синхронизации, в середине плотная инженерия, ближе к защите — продукт и история для стейкхолдеров.



1. День 0 — до буткемпа: просто понять язык

Пока никто ничего не кодит ради скрина. Читаем и договариваемся, что значат слова.

00 Теория и насмотренность

ЧТО ДЕЛАЕМ

1. Лонгриды и семинары: признаки, overfitting, train/test, метрики — чтобы потом не путаться.
2. NLP-база: токены, BIO, чем NER отличается от «классифицируем весь запрос целиком».
3. CRF vs «давайте сразу нейросеть»: когда хватает модели на признаках токена.
4. Эмбединги и косинус — это задел под поиск. В день 1 тащить не обязательно.
5. Трансформеры понимать полезно, но тяжёлый BERT в MVP под SLA < 100 мс на CPU явно не тащим.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. У всех в голове один словарь: факт, SKU, weak label, entity F1, latency.
2. Короткий конспект на команду: что прочитали и что реально берём в кейс.

Что читать: лонгриды курса, куски про последовательности / attention, TF-IDF и $P/R/F1$. Свои источники — ок, главное чтобы команда говорила на одном языке.

2. День 01 — Погружение, но сразу лезем в данные

День не заканчивается только планом на доске. К вечеру parquet уже открыт.

01 Синхронизация + репо + первый взгляд

ЧТО ДЕЛАЕМ

1. Сверить кейс: запрос → JSON с фактами, быстрее 100 мс. Иначе зачем всё это.
2. Роли набросать (данные, модель, сервис/UI, доки), но без культа «это не моё».
3. Зафиксировать JSON: brand, category, attributes, entities, latency_ms.
4. Поднять репозиторий, гигабайты сырых данных в gitignore, черновик README.
5. Открыть query_clicks и sku_desc: схемы, размеры, штук 20 живых строк в ноутбук.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Этот roadmap утверждён как рабочий план на дни 2–5.
2. Ноутбук overview: колонки, объёмы, без магии «оно само».

3. День 02 — Сюда нельзя опоздать: EDA + MVP

Если к вечеру нет JSON-сервиса — на день 3 не прыгаем в «приложение мечты». Сначала дожимаем факты.

02 EDA, словари, CRF, тонкий сервис

ЧТО ДЕЛАЕМ

1. EDA: длины запросов, топы, цена vs позиция, heatmaps — пачка картинок в figures/.
2. Из кликов собрать словари брендов и категорий → artifacts/*.txt.
3. Правила на ATTR (память, цвет, диагональ...) + авто-BIO.
4. Обучить CRF: по сути максимизируем $P(y | x)$, где y — теги, x — слова запроса.
5. Поднять /extract (и debug), чтобы любой из команды вбил запрос и сразу увидел JSON.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. EDA закрыт: ноутбуки + куча графиков.
2. MVP-ядро живо: запрос → факты, latency нормально укладывается в SLA.
3. В доке честно написано: метрики пока против weak labels, не против ручного gold.

Gate дня 2. Нет JSON к вечеру — эмбединги и standalone подождают.
Сначала извлечение фактов, потом красоты.

4. День 03 — Своя разметка и шесть ударов по качеству

Тут перестаём слепо верить словарю и начинаем мерить правду.

03 Gold / синтетика / переобучение

ЧТО ДЕЛАЕМ

1. Руками разметить пачку запросов (лучше сотни, не три примера). Span + тип.
2. Чуть синтетики: шаблоны «категория бренд attr» + шум и опечатки.
3. Прогнать текущий CRF по gold — вот это уже честный F1.
4. Закрыть шесть пунктов ниже хотя бы в версии v1.
5. Переобучить модель на смеси weak + gold.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Gold-файл в репо + скрипт оценки на нём.
2. Табличка «было / стало» по типичным косякам.

Шесть пунктов — это backlog, а не мечты в стол

1. Факты точнее — меньше мусора, фильтры поиска не врут.
2. Бренд и модель не путаем: iphone / galaxy s25 — это не всегда просто vendor-строка.
3. Нормализация: айфон / iphone / Apple сходятся к одному канону.
4. Устойчивость к шуму: опечатки, регистр, склейки вроде 16гб.
5. Своя разметка + синтетика — честные метрики, а не self-check словаря.

6. Score пары query↔click: бренд совпал, токены в title, позиция клика. Берём «хорошо согласованные» пары, без сказки про 100% идеал.

5. День 04 — Standalone: NER внизу, поиск сверху

Эмбединги не вместо NER. Вместе.


04 Приложение + поиск по каталогу

ЧТО ДЕЛАЕМ

1. UI: строка поиска, подсветка сущностей, JSON, latency vs 100 мс.
2. Индекс по sku_desc / куску каталога. На старте можно TF-IDF+SVD, если sentence-embeddings не влезают по времени.
3. Гибрид: буст/фильтры по фактам NER + близость запрос-SKU в пространстве.
4. Сделать 5-10 выдач «до / после фактов» — это лучший слайд на защите.
5. Заготовка под пункт 6: таблица high-score пар query-click.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Демо: вбил запрос → увидел факты и топ SKU.
2. Одна схема на слайд: query → NER → facts → retrieve → SKU.



6. День 05 — Упаковка и защита

05 История для людей, не только git log

ЧТО ДЕЛАЕМ

1. Питч: проблема → факты → метрики (weak vs gold) → демо → что дальше.
2. Прогнать живые сценарии: голая категория, бренд+ATTR, грязный запрос, и где модель тупит.
3. Ретро без понтов: что срезали, что переоценили, где клики ввали.

ЧТО ДОЛЖНО ПОЛУЧИТЬСЯ

1. Защита с живым демо и честной зоной роста.
2. After: нормальный dual-encoder, больше gold, когда-нибудь A/B на выдаче.

7. Кто за что (без бюрократии)

Зона	Фокус
Данные / EDA	parquet, графики, словари, score query-click
NER / метрики	BIO, CRF, gold, F1, нормализация
Поиск / app	UI, индекс, эмбединги, гибридная выдача
Доки / питч	LaTeX, README, слайды, «рассказать за 5 минут»

8. Чего сознательно не делаем

1. Не тащим огромный LLM в runtime, если он убивает SLA.
2. Не рисуем 40 графиков вместо gold-разметки на день 3.
3. Не обещаем «идеальный поиск М.Видео за неделю». Обещаем рабочий контур факты→выдача и понятный next step.

Если день 2 горит — режем эмбединги до простого TF-IDF.
Но JSON-MVP и честность про метрики не режем.