

ИНТЕЛЛЕКТУАЛЬНЫЙ ПОИСК

ДОКУМЕНТАЦИЯ РЕШЕНИЯ

Извлечение сущностей из поисковых запросов

Репозиторий:

<https://github.com/xWooshieL/mvideo-ner-search>

Дата: 18 июля 2026

SLA: ответ сервиса < 100 мс (JSON)

Содержание

Терминология и сокращения	3
1 Введение	4
1.1 О кейсе	4
1.2 Критерий успеха	4
1.3 Дорожная карта буткемпа	4
2 Данные	5
2.1 Файлы кейса	5
2.2 Наблюдения EDA	5
3 Методология	11
3.1 Слабая разметка (weak supervision)	11
3.2 Модели	11
3.3 Формат ответа	11
4 Результаты и метрики	12
5 Структура репозитория	16
5.1 Ноутбуки	16
6 Запуск	17
7 Выводы и следующие шаги	17

Терминология и сокращения

1. **NER** — Named Entity Recognition, распознавание именованных сущностей.
2. **BIO** — схема разметки токенов: Begin / Inside / Outside.
3. **SKU** — Stock Keeping Unit, единица товарного учёта.
4. **CRF** — Conditional Random Field, модель последовательности для NER.
5. **TF-IDF** — Term Frequency – Inverse Document Frequency.
6. **Weak supervision** — автоматическая разметка по словарям и правилам.
7. **YML** — Yandex Market Language, формат товарного каталога.
8. **SLA** — целевое время ответа сервиса (< 100 мс).

1. Введение

1.1. О кейсе

Поисковая система М.Видео должна **определять категорию, бренд и характеристики** товара в пользовательском запросе. Ошибки разбора ведут к нерелевантной выдаче и потере конверсии.


Цель буткемпа

Построить алгоритм/сервис, который на вход получает строку-запрос и менее чем за **100 мс** возвращает структурированный JSON с извлечёнными фактами.

1.2. Критерий успеха

1. Словари, модели и/или сервис на Python.
2. Структурированный JSON: сущности, бренд, категория, атрибуты.
3. Latency p95 существенно ниже 100 мс на CPU.
4. Метрики качества: Accuracy, Precision, Recall, F1.

1.3. Дорожная карта буткемпа



2. Данные

2.1. Файлы кейса

Файл	Объём	Содержание
query_clicks.parquet	~31M строк	Клики: запрос → SKU, бренд, цена, позиция
sku_desc.parquet	~1.18M строк	Карточки: sku_id, title, description
skus.pkl	~1.5 GB	YML-каталог yml_catalog.shop

Схема query_clicks

Поля после переименования: sku_id, sku_name, sku_brand_name, sku_price, sku_subject_id, sku_seo_id, query_text, sku_position. Полный датасет: ≈ 1.79 M уникальных запросов, 333k SKU, 7.1k брендов, 4.1k subject_id.

2.2. Наблюдения EDA

- Топ-запросы — категорийные: «стиральная машинка», «холодильники», «аэрогриль», «телевизор», «ноутбук», «смартфон».
- Топ-бренды по кликам: Apple, Samsung, Haier, Xiaomi, HUAWEI, Tefal, Gorenje, Яндекс, Indesit, HONOR, LG.
- Значимая доля кликов приходится на верх выдачи (малая позиция).
- Цены имеют тяжёлый хвост (premium-сегмент / outliers).




Рис. 1: Топ поисковых запросов по кликам




Рис. 2: Топ брендов




Рис. 3: Распределение длины запросов




Рис. 4: Распределение цен кликнутых SKU




Рис. 5: Позиция SKU при клике




Рис. 6: Co-occurrence: запрос × бренд




Рис. 7: Матрица косинусной близости TF-IDF запросов




Рис. 8: Цена vs позиция в выдаче

3. Методология

3.1. Слабая разметка (weak supervision)

Из кликовых данных строятся словари брендов и категорийных фраз. По ним запросы размечаются в BIO-схеме с типами:

- **BRAND** — бренд (Apple, Samsung, ...);
- **CATEGORY** — тип товара (ноутбук, холодильник, ...);
- **ATTR** — характеристики (256 ГБ, OLED, цвет, диагональ).

3.2. Модели

Средняя сложность — гибрид

1. **Baseline:** TF-IDF (char n -grams) + Logistic Regression → бренд по запросу.
2. **NER:** CRF (`sklearn-crfsuite`) на орфографических и контекстных признаках токена.
3. **Инференс:** словарь (exact) + RapidFuzz (fuzzy brand) + CRF → JSON.

Подход опирается на классические идеи курса ИИ: векторные представления текста, модели последовательностей, метрики классификации/NER, оптимизация latency для продакшн-сервиса.

3.3. Формат ответа

POST /extract

```
{"query": "смартфон apple 256"}
```

```
-> {
  "query": "...",
  "entities": [{"text": "apple", "label": "BRAND", ...}],
  "brand": "Apple",
  "category": "смартфон",
  "attributes": {"256": "ATTR"},
  "latency_ms": 2.1
}
```

4. Результаты и метрики

Актуальные числа сохраняются в `artifacts/metrics.json` после запуска пайплайна.




Рис. 9: Сводка метрик: classifier / NER / latency




Рис. 10: Confusion matrix предсказания бренда




Рис. 11: Entity F1 по типам сущностей




Рис. 12: Learning curve CRF NER




Рис. 13: t-SNE проекция запросов




Рис. 14: Гистограмма latency инференса

SLA

Целевой порог — 100 мс. Гибридный словарь+CRF на CPU обычно укладывается в единицы миллисекунд (см. p50/p95 в `metrics.json`).

5. Структура репозитория

Путь	Назначение
<code>notebooks/01-12_*.ipynb</code>	EDA, схожести, NER, сервис, демо
<code>scripts/run_pipeline.py</code>	Полный прогон: графики + обучение + метрики
<code>src/ner/</code>	Разметка, признаки, CRF, extractor
<code>src/service/app.py</code>	FastAPI /extract
<code>figures/</code>	PNG-визуализации (>10)
<code>artifacts/</code>	Словари, <code>metrics.json</code>
<code>models/</code>	<code>crf_ner.pkl</code> , baseline joblib
<code>docs/</code>	Эта LaTeX-документация
<code>файлы/</code>	Сырые данные (не в git)

5.1. Ноутбуки

1. `01_data_overview` — схемы и размеры;
2. `02_eda_queries` — запросы;
3. `03_eda_products` — товары/бренды;
4. `04_similarity_matrices` — матрицы схожести;
5. `05_click_patterns` — клики и позиции;
6. `06_weak_supervision_ner` — BIO-разметка;
7. `07_train_baseline_classifier` — TF-IDF + LogReg;
8. `08_train_ner_model` — CRF NER;
9. `09_embeddings_similarity` — эмбединги / t-SNE;
10. `10_service_benchmark` — latency;
11. `11_skus_catalog_explore` — YML-каталог;
12. `12_end_to_end_demo` — демо JSON.

6. Запуск

```
pip install -r requirements.txt
python scripts/run_pipeline.py
uvicorn src.service.app:app --port 8000
```

GitHub

Репозиторий: <https://github.com/xWooshieL/mvideo-ner-search>.

Администратор-коллаборатор: Nizier193.

7. Выводы и следующие шаги

1. Гибрид словарей и CRF даёт интерпретируемый и быстрый NER для e-commerce запросов.
2. Weak supervision масштабируется на миллионы кликов без ручной разметки.
3. Дальше: дообучение tiny-трансформера (RuBERT-tiny), нормализация опечаток, связка с ранжированием выдачи, онлайн A/B.




Рис. 15: Доп. матрица схожести запросов




Рис. 16: Распределение сущностей в weak-labeled данных




Рис. 17: Цены по топ-брендам

Документация подготовлена для защиты кейса М.Видео — буткемп ЦУ 2026