

ДЕНЬ 02 · БУТКЕМП М.ВИДЕО · NLP / SEARCH

EDA, гипотезы и слоистый NER

Что мы увидели в 31 млн кликов, какие гипотезы подтвердились, и почему задача кейса — не «обычный NER», а максимум покрытия edge-cases.

Intelligent Search · Query Understanding

ДЕНЬ 02 · ИТОГИ

Что сделали сегодня

ВЫВОД EDA закрыт, гипотезы проверены на данных, архитектура решения переосмыслена под edge-cases.

1 EDA

31 млн кликов, 1.79 млн запросов: длины, топы, цены, позиции, схожести.

2 Гипотезы

Сформулировали и проверили: что подтвердилось, а что нет.

3 Слои NER

Правила → CRF → трансформеры: вероятностное пространство, а не один молоток.

4 Разметка

План ручной разметки match 0/1 и марковская модель для атрибутов.

ДАННЫЕ · МАСШТАБ

С чем работаем

ВЫВОД Данных достаточно и для словарей, и для обучения: узкое место не объём, а качество меток.

30.99 млн

кликов: запрос → SKU
(query_clicks.parquet)

1.79 млн

уникальных запросов

1.18 млн

карточек title + description
(sku_desc.parquet)

333 тыс

уникальных SKU в кликах

7 150

брендов


546 тыс

офферов в YML-каталоге (6 963
категории)

Пример строки клика

query: «galaxy s25»
sku: Смартфон Samsung Galaxy
S25 FE 8/256GB Black
brand: Samsung · price: 50 703
₽ · position: 2


Запросы короткие и категорийные



Вывод Голова трафика — категории без бренда: «стиральная машинка», «холодильники», «аэрогриль».

- 1 Медианная длина запроса $\approx$ 15–17 символов, 1–3 токена.
- 2 В топ-15 нет атрибутов: люди уточняют фильтрами или кликами.
- 3 Категорию надо ловить идеально — самый частый факт.


Бренды: голова мощная, хвост длинный



ВЫВОД Топ-15 брендов покрывает огромную долю кликов, но хвост из 7 тысяч брендов правилами не закрыть.

- 1 Apple, Samsung, Haier, Xiaomi — лидеры кликов.
- 2 Цены с тяжёлым хвостом: медиана 16 тыс. ₽, средняя 31 тыс. ₽.
- 3 Словарь брендов — сильный, но конечный: нужен слой для редких написаний.

Клики живут в топе выдачи




ВЫВОД Медианная позиция клика — 4. Ошибка разбора запроса почти гарантированно теряет клик.

- 1 75% кликов — в первых 16 позициях.
- 2 Позиция клика — полезный сигнал качества пары $query \leftrightarrow SKU$ (пригодится для разметки match).
- 3 Связь цены и позиции слабая: дорогие товары кликают и в топе, и глубоко.

EDA · КЛЮЧЕВОЙ ИНСАЙТ

73% брендов нет в тексте запроса


Где находится бренд: запрос vs карточка клика



ВЫВОД Только в **27%** кликов бренд написан в запросе. В **73%** бренд известен лишь у карточки — одним словарём его не достать.

- 1 Отсюда обязателен слой **бренд-классификатора** по кликам: «айфон 15» → Apple, хотя слова «Apple» нет.
- 2 Клики — не мусор, а обучающий сигнал: самый частый бренд запроса даёт метку без ручной разметки.
- 3 Ограничение: **17%** запросов кликают ≥ 2 бренда — берём частотный с весом по позиции.

Запрос короткий, но границы важны



ВЫВОД Медиана 2 токена, 90% запросов ≤ 4 слов, 99% ≤ 8 слов — CRF летает на CPU под SLA.

- 1 Перцентили длины: половина запросов ≤ 2 слов, 9 из 10 ≤ 4 , почти все (99%) ≤ 8 .
- 2 Слабая разметка даёт ≥ 1 сущность у **~80%** запросов: BRAND ~46%, CATEGORY ~59%, ATTR ~7%.
- 3 У **~27%** запросов есть I-* — многословные сущности, нужны именно границы span (BIO).



EDA · ПРОВЕРКА ГИПОТЕЗ

Гипотезы: что подтвердилось

Гипотеза	Статус	Комментарий
Н1. Запросы — короткие категорийные интенды	Да	топы — чистые категории
Н2. Клики концентрируются в топе выдачи	Да	медиана позиции = 4
Н3. Бренд в запросе $\Rightarrow$ клик того же бренда	В основном	heatmap диагональна
Н4. Цена сильно влияет на позицию клика	Нет	hexbin: связь слабая
Н5. Атрибуты пишут единообразно	Нет	«16гб», «16 gb», «16 ГБ»
Н6. Бренд обычно написан в запросе	Нет	только 27% — нужен классификатор

Красное = подтверждено данными. Н5 — главный аргумент за вероятностный подход: атрибуты не закрыть одним regex.

Н1: запросы короткие и категорийные





ВЫВОД Медиана длины запроса — **17 символов** ($\approx 1-3$ слова), а в топе — чистые категории без бренда и атрибутов.

- 1 Распределение длины (сверху) собрано в районе 10–20 символов — люди пишут коротко.
- 2 Топ запросов (снизу): «стиральная машинка», «холодильники», «аэрогриль» — это категории, а не модели.
- 3 Значит категорию надо ловить идеально: это самый частый и самый короткий факт в запросе.

ДОКАЗАТЕЛЬСТВО · Н2

Н2: клики концентрируются в топе




ВЫВОД Медиана позиции клика — **4**, а первые позиции забирают львиную долю: ошибка разбора почти гарантированно теряет клик.

- 1 Распределение позиций (сверху) резко смещено влево — кликают по верхним строкам выдачи.
- 2 Накопленная доля (снизу): $\approx 75\%$ кликов приходится на первые 16 позиций.
- 3 Вывод для нас: точность разбора запроса прямо конвертируется в клик — промах отправляет товар вниз, куда не смотрят.

Что нашли, когда прочитали данные руками

Полнота карточки в кликах



ВЫВОД Датасет собирал человек — в нём есть системные дыры и ошибки. Их надо чистить до обучения, иначе модель учится на мусоре.

- 1 Только **72%** кликов имеют полную карточку (бренд + название + цена).
- 2 У **22%** карточка вообще не подтянулась — пусты и бренд, и название (join не срослось при сборке).
- 3 Формальных NaN нет — дыры спрятаны в пустых строках "", их легко не заметить.

КАЧЕСТВО ДАННЫХ · ПЕРЕПУТАННЫЕ КОЛОНКИ

Артикул уехал в поле бренда

ВЫВОД В 66 строках **бренд — это просто число**. В 98,5% случаев это артикул из середины названия, попавший не в ту колонку.

Название товара (sku_name)	Поле «бренд»	Реальность
Вентилятор напольный 27942 GL 8112	27942	артикул
Камера видеонаблюдения 360 V380 Pro APP	360	артикул
Туфли женские 0 Туфли	0	заглушка
Бритва 4088 Extra Smooth Embrace	4088	артикул

Правило для нас: числовой sku_brand_name — не бренд, а шум. Реальный бренд ищем в тексте названия либо считаем, что его нет.

КАЧЕСТВО ДАННЫХ · ТРАНСЛИТ

Транслит, смесь языков и омоглифы

Масштаб проблем данных (% от семпла)



ВЫВОД 35% уникальных запросов — смесь кириллицы и латиницы. Модель обязана быть устойчива к раскладке.

Тип	Пример из данных
Смесь	«iPhone 17 про Макс», «bosh лодильник»
Транслит	«noutbuk», «televizor», «Stiralnay»
Омоглиф	«Ресанта» (а — кир.), «Фаза»

КАЧЕСТВО ДАННЫХ · ДУБЛИ И МЕРЫ

Дубли брендов и что мы с этим делаем

Один бренд — много написаний

Проблема	Пример
Регистр	APPLE / Apple, honor / HONOR
Перевод	Stinol / Стинол, KION / КИОН
Дубли строк	один клик записан по 2–3 раза

Меры (слой нормализации)

- 1 Приводим бренды к канону: регистр, транслит, схлопывание дублей (**Стинол**=**Stinol**).
- 2 Фильтруем мусор до обучения: пустые карточки и цена ≤ 0 — вон или в отдельную метку.
- 3 Позиция = 0 — это «нет данных», не топ выдачи; не используем как сигнал.
- 4 Это прямой аргумент за **H5**: одним regex единообразие не навести.

205 групп брендов различаются лишь регистром/пробелами, ~209 групп — кандидаты на омоглифы.

ПОСТАНОВКА · ПЕРЕОСМЫСЛЕНИЕ

Задача — не «обычный NER»

ВЫВОД Главная цель — максимизировать покрытие edge-cases, а не выбить красивый F1 на простых запросах.

Почему так

- 1 Голова запросов решается словарём за день — это не подвиг.
- 2 Конверсию теряют хвосты: опечатки, редкие бренды, склейки, смесь языков.
- 3 Ценность решения = сколько хвоста мы покрываем при $SLA < 100$ мс.

Работаем в вероятностном пространстве

Каждый слой отдаёт не только ответ, но и уверенность. Если уверенность низкая — запрос уходит на слой тяжелее. Так простое остаётся быстрым, а сложное — решаемым.

АРХИТЕКТУРА · СЛОИ

Три слоя: голова, середина, хвост



ВЫВОД Каскад по уверенности: 90% трафика решают дешёвые слои, тяжёлые модели работают только там, где реально нужны.

ИДЕЯ · МАРКОВСКАЯ МОДЕЛЬ

Марковская цепь для атрибутов

ВЫВОД По предыдущему токenu предсказываем тип следующего: после «16» вероятнее всего «гб» — значит, это memory.



attributes: {«memory»: «16 гб»} — юнит восстановлен из контекста, даже если пользователь его не дописал

- 1 Обучаем переходы $P(t_{i+1} | t_i)$ на миллионах запросов — бесплатная статистика.
- 2 Число без юнита перестаёт быть загадкой: «16» перед «гб» — память, перед «дюймов» — диагональ.
- 3 Дёшево, интерпретируемо, работает в голове каскада рядом с правилами.

ИДЕЯ · РАЗМЕТКА MATCH

Match 0/1: запрос попал в карточку?

ВЫВОД 100+ пар размечаем руками: 1 — клик полностью соответствует запросу, 0 — иначе. Модель доразмечает остальное.

Что это даёт

- 1 «Хорошие запросы» — кандидаты на улучшение NER: запрос $\approx$ описанию карточки.
- 2 Чистим шум: «искал айфон → кликнул чехол» не портит обучение.
- 3 На метке 1 учим $\text{embed}(\text{query}) \approx \text{embed}(\text{title} + \text{desc})$: описание дотаскивает цвет, память, синонимы.

Как используем скор

NER достал факты → фильтр и буст в выдаче



$P(\text{match} = 1 \mid \text{query}, \text{sku_text})$ — перанк
поверх



модель: градиентный бустинг (CatBoost / XGBoost) на простых признаках

CRF на слабой BIO-разметке: где мы сейчас

ВЫВОД Метрики на серебряных метках оптимистичны — это ориентир, а не финальная оценка. Нужен золотой набор 3000–5000 запросов, размеченный вручную.

Быстрый тест на выборке

Token accuracy	0.89
Entity micro-F1	0.85
F1 BRAND	0.95
F1 CATEGORY	0.78
F1 ATTR	0.85

Что это значит

- 1** BRAND учится легко (0.95) — словарь почти решает задачу в голове каскада.
- 2** CATEGORY слабее (0.78) — формулировки разнообразнее, тут нужен либо трансформер, либо больше слабо-размеченных данных.
- 3** Итог: CRF — рабочая середина каскада, но категорию и хвост дотягиваем следующим слоем.

РИСКИ · ЧЕСТНО

Подводные камни и что с ними делать

Риск	Последствие	Меры снижения
«Соответствие» размыто	«dyson» → пылесос Dyson: 1 или 0?	жёсткий гайд разметки до старта
100 примеров маловато	модель выучит шум выборки	300–700 меток в день + согласие
Самореференция	ошибки размножаются на своих метках	holdout gold вне авторазметки
Путаница с NER	это query↔SKU, не BIO на словах	отдельные пайплайны и метрики

Каждый риск закрыт конкретной мерой снижения ещё до старта разметки.

ПЛАН · ДАЛЬШЕ

План разметки и следующие шаги

Разметка

- 1 Каждый день от каждого в команде: 300–700 пар вручную.
- 2 Остальное — автоматика: правила, алгоритмы, ИИ-агенты с выборочной проверкой глазами.
- 3 Gold-holdout откладываем сразу и не трогаем до финальной оценки.

Следующие шаги

- 4 Марковская модель атрибутов → в голову каскада.
- 5 CRF на середину, сравнение BIO vs span-level.
- 6 Матч-модель (бустинг) на первых 100+ метках → серебряные метки → реранк с описанием карточки.

ВЫВОД К защите: каскад с покрытием edge-cases + честные метрики на ручном gold, а не self-check словаря.

Спасибо!

Вопросы, критика гипотез и споры про слои — welcome.

Команда:

Новицкий Никита · @n.novitskiy

Борисов Никита · @n.borisov

Засухина Елизавета · @e.zasukhina

Олейников Александр · @a.oleynikov