

ДЕНЬ 02 · БУТКЕМП М.ВИДЕО · NLP / SEARCH

# EDA, гипотезы и слоистый NER

Что мы увидели в 31 млн кликов, какие гипотезы подтвердились, и почему задача кейса — не «обычный NER», а максимум покрытия edge-cases.

Intelligent Search · Query Understanding

## ДЕНЬ 02 · ИТОГИ

# Что сделали сегодня

**ВЫВОД** EDA закрыт, гипотезы проверены на данных, архитектура решения переосмыслена под edge-cases.

### 1 EDA

31 млн кликов, 1.79 млн запросов: длины, топы, цены, позиции, схожести.

### 2 Гипотезы

Сформулировали и проверили: что подтвердилось, а что нет.

### 3 Слои NER

Правила → CRF → трансформеры: вероятностное пространство, а не один молоток.

### 4 Разметка

План ручной разметки match 0/1 и марковская модель для атрибутов.

## ДАННЫЕ · МАСШТАБ

# С чем работаем

**ВЫВОД** Данных достаточно и для словарей, и для обучения: узкое место не объём, а качество меток.

**30.99 млн**

кликов: запрос → SKU  
(query\_clicks.parquet)

**1.79 млн**

уникальных запросов

**1.18 млн**

карточек title + description

**333 тыс**

уникальных SKU в кликах

**7 150**

брендов

**546 тыс**


офферов в YML-каталоге (6 963  
категории)

### Пример строки клика

query: «galaxy s25»  
sku: Смартфон Samsung  
Galaxy S25 FE 8/256GB Black  
brand: Samsung · price: 50  
703 ₽ · position: 2

## EDA · ЗАПРОСЫ

# Запросы короткие и категорийные




**ВЫВОД** Голова трафика — категории без бренда: «стиральная машинка», «холодильники», «аэрогриль».

- 1 Медианная длина запроса  $\approx 15-17$  символов, 1–3 токена.
- 2 В топ-15 нет атрибутов: люди уточняют фильтрами или кликами.
- 3 Категорию надо ловить идеально — самый частый факт.

## EDA · БРЕНДЫ И ЦЕНЫ

## Бренды: голова мощная, хвост длинный




**ВЫВОД** Топ-15 брендов покрывает огромную долю кликов, но хвост из 7 тысяч брендов правилами не закрыть.

- 1 Apple, Samsung, Haier, Xiaomi — лидеры кликов.
- 2 Цены с тяжёлым хвостом: медиана 16 тыс. ₽, средняя 31 тыс. ₽ — premium тянет вправо.
- 3 Словарь брендов — сильный, но конечный инструмент: нужен слой для

## EDA · КЛИКИ

# Клики живут в топе выдачи



**ВЫВОД** Медианная позиция клика — 4. Ошибка разбора запроса почти гарантированно теряет клик.

- 1 75% кликов — в первых 16 позициях.
- 2 Позиция клика — полезный сигнал качества пары query↔SKU (пригодится для разметки match).
- 3 Связь цены и позиции слабая: дорогие товары кликают и в топе, и глубоко.

## EDA · ПРОВЕРКА ГИПОТЕЗ

## Гипотезы: что подтвердилось

| Гипотеза                                                 | Статус     | Комментарий                              |
|----------------------------------------------------------|------------|------------------------------------------|
| H1. Большинство запросов — короткие категорийные интенды | да         | топы — чистые категории                  |
| H2. Клики концентрируются в топе выдачи                  | да         | медиана позиции = 4                      |
| H3. Бренд в запросе $\Rightarrow$ клик по тому же бренду | В ОСНОВНОМ | heatmap query $\times$ brand диагональна |
| H4. Цена сильно влияет на позицию клика                  | нет        | hexbin: связь слабая                     |
| H5. Атрибуты в запросах пишут единообразно               | нет        | «16гб», «16 gb», «16 ГБ» — зоопарк       |

**ВЫВОД** H5 — главный аргумент за вероятностный подход: атрибуты

## ПОСТАНОВКА · ПЕРЕОСМЫСЛЕНИЕ

# Задача --- не «обычный NER»

**ВЫВОД** Главная цель — максимизировать покрытие edge-cases, а не выбить красивый F1 на простых запросах.

### Почему так

- 1 Голова запросов решается словарём за день — это не подвиг.
- 2 Конверсию теряют хвосты: опечатки, редкие бренды, склейки, смесь языков.
- 3 Ценность решения = сколько хвоста мы покрываем при  $SI A < 100$

### Работаем в вероятностном пространстве

Каждый слой отдаёт не только ответ, но и уверенность. Если уверенность низкая — запрос уходит на слой тяжелее. Так простое остаётся быстрым, а сложное — решаемым.

## АРХИТЕКТУРА · СЛОИ

# Три слоя: голова, середина, хвост



**ВЫВОД** Каскад по уверенности: 90% трафика решают дешёвые слои, тяжёлые модели работают только там, где реально нужны.

## ИДЕЯ · МАРКОВСКАЯ МОДЕЛЬ

## Марковская цепь для атрибутов

**ВЫВОД** По предыдущему токenu предсказываем тип следующего: после «16» вероятнее всего «гб» — значит, это memory.



- 1 Обучаем переходы  $P(t_{i+1} | t_i)$  на миллионах запросов — бесплатная статистика.
- 2 Число без юнита перестаёт быть загадкой: «16» перед «гб» — память, перед «дюймов» — диагональ.

- 3 Дёшево, интерпретируемо, работает

attributes: {«memory»: «16 гб»} — юнит восстановлен из контекста, даже если пользователь его не дописал

## ИДЕЯ · РАЗМЕТКА MATCH

# Match 0/1: запрос попал в карточку?

**ВЫВОД** 100+ пар размечаем руками: 1 — клик полностью соответствует запросу, 0 — иначе. Модель доразмечает остальное.

### Что это даёт

- 1 «Хорошие запросы» — кандидаты на улучшение NER: запрос  $\approx$  описанию карточки.
- 2 Чистим шум: «искал айфон → кликнул чехол» не портит обучение.
- 3 На метке 1 учим  $\text{embed}(\text{query}) \approx \text{embed}(\text{title} + \text{desc})$ : описание дотаскивает

### Как используем скор

NER достал факты → фильтр и буст в выдаче

$P(\text{match} = 1 \mid \text{query}, \text{sku\_text})$  — перанк поверх

модель: градиентный бустинг (CatBoost / XGBoost) на простых фичах

## РИСКИ · ЧЕСТНО

## Подводные камни и что с ними делать

| Риск                          | Почему больно                                         | Решение                                            |
|-------------------------------|-------------------------------------------------------|----------------------------------------------------|
| «Полное соответствие» размыто | «dyson» → пылесос Dyson — это 1 или 0?                | жёсткий гайд разметки с примерами до старта        |
| 100 примеров маловато         | модель выучит шум выборки                             | 300–700 меток в день с каждого + проверка согласия |
| Самореференция                | модель учится на своих же метках, ошибки размножаются | holdout gold, который модель никогда не размечала  |
| Путаница с NER                | это про query↔SKU, не про BIO на словах               | отдельные пайплайны, отдельные метрики             |

**ВЫВОД** Каждому риску — конкретный процесс, а не «будем аккуратнее».

## ПЛАН · ДАЛЬШЕ

# План разметки и следующие шаги

### Разметка

- 1 Каждый день от каждого в команде: 300–700 пар вручную.
- 2 Остальное — автоматика: правила, алгоритмы, ИИ-агенты с выборочной проверкой глазами.
- 3 Gold-holdout откладываем сразу и не трогаем до финальной оценки.

### Следующие шаги

- 4 Марковская модель атрибутов → в голову каскада.
- 5 CRF на середину, сравнение BIO vs span-level.
- 6 Матч-модель (бустинг) на первых 100+ метках → silver labels → перанк с description.

**ВЫВОД** К защите: каскад с покрытием edge-cases + честные метрики на ручном gold, а не self-check словаря.

# Спасибо!

Вопросы, критика гипотез и споры про  
слои — welcome.

День 02 · EDA и гипотезы · Буткемп М.Видео