

ДЕНЬ 02 · БУТКЕМП М.ВИДЕО · NLP / SEARCH

EDA, гипотезы и слоистый NER

Что мы увидели в 31 млн кликов, какие гипотезы подтвердились, и почему задача кейса — не «обычный NER», а максимум покрытия edge-cases.

Intelligent Search · Query Understanding

ДЕНЬ 02 · ИТОГИ

Что сделали сегодня

ВЫВОД EDA закрыт, гипотезы проверены на данных, архитектура решения переосмыслена под edge-cases.

1 EDA

31 млн кликов, 1.79 млн запросов: длины, топы, цены, позиции, схожести.

2 Гипотезы

Сформулировали и проверили: что подтвердилось, а что нет.

3 Слои NER

Правила → CRF → трансформеры: вероятностное пространство, а не один молоток.

4 Разметка

План ручной разметки match 0/1 и марковская модель для атрибутов.

ДАННЫЕ · МАСШТАБ

С чем работаем

ВЫВОД Данных достаточно и для словарей, и для обучения: узкое место не объём, а качество меток.

30.99 млн

кликов: запрос → SKU
(query_clicks.parquet)

1.79 млн

уникальных запросов

1.18 млн

карточек title + description
(sku_desc.parquet)

333 тыс

уникальных SKU в кликах

7 150

брендов


546 тыс

офферов в YML-каталоге (6 963
категории)

Пример строки клика

query: «galaxy s25»
sku: Смартфон Samsung Galaxy
S25 FE 8/256GB Black
brand: Samsung · price: 50 703
₽ · position: 2


Запросы короткие и категорийные



ВЫВОД Голова трафика — категории без бренда: «стиральная машинка», «холодильники», «аэрогриль».

- 1 Медианная длина запроса $\approx$ 15–17 символов, 1–3 токена.
- 2 В топ-15 нет атрибутов: люди уточняют фильтрами или кликами.
- 3 Категорию надо ловить идеально — самый частый факт.


Бренды: голова мощная, хвост длинный



ВЫВОД Топ-15 брендов покрывает огромную долю кликов, но хвост из 7 тысяч брендов правилами не закрыть.

- 1 Apple, Samsung, Haier, Xiaomi — лидеры кликов.
- 2 Цены с тяжёлым хвостом: медиана 16 тыс. ₽, средняя 31 тыс. ₽.
- 3 Словарь брендов — сильный, но конечный: нужен слой для редких написаний.

Клики живут в топе выдачи




ВЫВОД Медианная позиция клика — 4. Ошибка разбора запроса почти гарантированно теряет клик.

- 1 75% кликов — в первых 16 позициях.
- 2 Позиция клика — полезный сигнал качества пары $query \leftrightarrow SKU$ (пригодится для разметки match).
- 3 Связь цены и позиции слабая: дорогие товары кликают и в топе, и глубоко.

EDA · КЛЮЧЕВОЙ ИНСАЙТ

73% брендов нет в тексте запроса


Где находится бренд: запрос vs карточка клика



ВЫВОД Только в **27%** кликов бренд написан в запросе. В **73%** бренд известен лишь у карточки — одним словарём его не достать.

- 1 Отсюда обязателен слой **бренд-классификатора** по кликам: «айфон 15» → Apple, хотя слова «Apple» нет.
- 2 Клики — не мусор, а обучающий сигнал: самый частый бренд запроса даёт метку без ручной разметки.
- 3 Ограничение: **17%** запросов кликают ≥ 2 бренда — берём частотный с весом по позиции.

Запрос короткий, но границы важны



ВЫВОД Медиана 2 токена, 90% запросов ≤ 4 слов, 99% ≤ 8 слов — CRF летает на CPU под SLA.

- 1 Перцентили длины: половина запросов ≤ 2 слов, 9 из 10 ≤ 4 , почти все (99%) ≤ 8 .
- 2 Слабая разметка даёт ≥ 1 сущность у **~80%** запросов: BRAND ~46%, CATEGORY ~59%, ATTR ~7%.
- 3 У **~27%** запросов есть I-* — многословные сущности, нужны именно границы span (BIO).



EDA · ПРОВЕРКА ГИПОТЕЗ

Гипотезы: что подтвердилось

Гипотеза	Статус	Комментарий
Н1. Запросы — короткие категорийные интенды	Да	топы — чистые категории
Н2. Клики концентрируются в топе выдачи	Да	медиана позиции = 4
Н3. Бренд в запросе $\Rightarrow$ клик того же бренда	В основном	heatmap диагональна
Н4. Цена сильно влияет на позицию клика	Нет	hexbin: связь слабая
Н5. Атрибуты пишут единообразно	Нет	«16гб», «16 gb», «16 ГБ»
Н6. Бренд обычно написан в запросе	Нет	только 27% — нужен классификатор

Красное = подтверждено данными. Н5 — главный аргумент за вероятностный подход: атрибуты не закрыть одним regex.

Н1: запросы короткие и категорийные





ВЫВОД Медиана длины запроса — **17 символов** ($\approx 1-3$ слова), а в топе — чистые категории без бренда и атрибутов.

- 1 Распределение длины (сверху) собрано в районе 10–20 символов — люди пишут коротко.
- 2 Топ запросов (снизу): «стиральная машинка», «холодильники», «аэрогриль» — это категории, а не модели.
- 3 Значит категорию надо ловить идеально: это самый частый и самый короткий факт в запросе.

ДОКАЗАТЕЛЬСТВО · Н2

Н2: клики концентрируются в топе




ВЫВОД Медиана позиции клика — **4**, а первые позиции забирают львиную долю: ошибка разбора почти гарантированно теряет клик.

- 1 Распределение позиций (сверху) резко смещено влево — кликают по верхним строкам выдачи.
- 2 Накопленная доля (снизу): $\approx 75\%$ кликов приходится на первые 16 позиций.
- 3 Вывод для нас: точность разбора запроса прямо конвертируется в клик — промах отправляет товар вниз, куда не смотрят.

Что нашли, когда прочитали данные руками

Полнота карточки в кликах



ВЫВОД Датасет собирал человек — в нём есть системные дыры и ошибки. Их надо чистить до обучения, иначе модель учится на мусоре.

- 1 Только **72%** кликов имеют полную карточку (бренд + название + цена).
- 2 У **22%** карточка вообще не подтянулась — пусты и бренд, и название (join не срослось при сборке).
- 3 Формальных NaN нет — дыры спрятаны в пустых строках "", их легко не заметить.

КАЧЕСТВО ДАННЫХ · ПЕРЕПУТАННЫЕ КОЛОНКИ

Артикул уехал в поле бренда

ВЫВОД В 66 строках **бренд** — это просто число. В 98,5% случаев это артикул из середины названия, попавший не в ту колонку.

Название товара (sku_name)	Поле «бренд»	Реальность
Вентилятор напольный 27942 GL 8112	27942	артикул
Камера видеонаблюдения 360 V380 Pro APP	360	артикул
Туфли женские 0 Туфли	0	заглушка
Бритва 4088 Extra Smooth Embrace	4088	артикул

Правило для нас: числовой sku_brand_name — не бренд, а шум. Реальный бренд ищем в тексте названия либо считаем, что его нет.

Транслит, смесь языков и омоглифы

Масштаб проблем данных (% от семпла)



ВЫВОД 35% уникальных запросов — смесь кириллицы и латиницы. Модель обязана быть устойчива к раскладке.

Тип	Пример из данных
Смесь	«iPhone 17 про Макс», «bosh лодильник»
Транслит	«noutbuk», «televizor», «Stiralnay»
Омоглиф	«Ресанта» (а — кир.), «Фaza»
Раскладка	«dfhjxyfz» → «варочная»

КАЧЕСТВО ДАННЫХ · ЗАБЫТАЯ РАСКЛАДКА

Печатали по-русски в EN-раскладке

Вывод Нашли **80+** запросов вида «dfhjxyfz gfytkm» — это «варочная панель», набранное в латинской раскладке. Поиск обязан их авто-исправлять.

Ввели (EN)

lkz djkc aty gkjqr f gkjqr
 pfhlyst ecnhjqcndf lkz
 frrevekjnhjd fdnj
 dfhjxyfz gfytkm ,tkjt cntrkh
 dbltjrfvthf lkz gjvtotybz
 dcnhfbdfvzf cnbhfkmyfz
 vfiby f
 le[jdq irfa 'ktrnhbxtcrbq
 pfhzyjt ecnhjqcndj czjvb
 rf,tkm lkz rkdbfnehs
 gsktcjc dthnbrfkmysq
 ghjdilyjq
 nhbvvth lkz yjcf
 'ktrnhbxtcrfz gkbnf akfvf
 ,tjdfz ljhj;rf

Хотели найти

для волос фен плойка плойка
 зарядные устройства для
 аккумуляторов авто
 варочная панель белое стекл
 видеокамера для помещения
 встраиваемая стиральная
 машина
 духовой шкаф электрический
 зарядное устройство сяоми
 кабель для клавиатуры
 пылесос вертикальный
 проводной
 триммер для носа
 электрическая плита флама
 беговая дорожка

Ввели (EN)

dtynbkznjh yfcnjkmysq
 dthnbrfkmysq gsktcjc
 dcnhfbdbdfvzf [kjlbkmybr
 dcnhjtyyfz gjceljvjqr f
 dcnhjtyysq [kjlbkmybr
 ufjpdfz gkbnf
 ufqrjdthn htldthu
 ukflbkmyfz ljcrf
 lhtkm ,eh
 pfdfhjxysq xfyqybr
 pfhzyjt ecnhjqcndj
 buhjdjt rhtckj
 buhjdjg hekm
 rkdbfnehf ,tkfz

Хотели найти

вентилятор настольный
 вертикальный пылесос
 встраиваемый холодильник
 встроенная посудомойка
 встроенный холодильник
 газовая плита
 гайковерт редверг
 гладильная доска
 дрель бур
 заварочный чайник
 зарядное устройство
 игровое кресло
 игровой руль
 клавиатура белая

КАЧЕСТВО ДАННЫХ · ДУБЛИ И МЕРЫ

Дубли брендов и что мы с этим делаем

Один бренд — много написаний

Проблема	Пример
Регистр	APPLE / Apple, honor / HONOR
Перевод	Stinol / Стинол, KION / КИОН
Дубли строк	один клик записан по 2–3 раза

Меры (слой нормализации)

- 1 Приводим бренды к канону: регистр, транслит, схлопывание дублей (**Стинол**=**Stinol**).
- 2 Фильтруем мусор до обучения: пустые карточки и цена ≤ 0 — вон или в отдельную метку.
- 3 Позиция = 0 — это «нет данных», не топ выдачи; не используем как сигнал.
- 4 Это прямой аргумент за **H5**: одним regex единообразие не навести.

205 групп брендов различаются лишь регистром/пробелами, ~209 групп — кандидаты на омоглифы.

ПОСТАНОВКА · ПЕРЕОСМЫСЛЕНИЕ

Задача — не «обычный NER»

ВЫВОД Главная цель — максимизировать покрытие edge-cases, а не выбить красивый F1 на простых запросах.

Почему так

- 1 Голова запросов решается словарём за день — это не подвиг.
- 2 Конверсию теряют хвосты: опечатки, редкие бренды, склейки, смесь языков.
- 3 Ценность решения = сколько хвоста мы покрываем при $SLA < 100$ мс.

Работаем в вероятностном пространстве

Каждый слой отдаёт не только ответ, но и уверенность. Если уверенность низкая — запрос уходит на слой тяжелее. Так простое остаётся быстрым, а сложное — решаемым.

АРХИТЕКТУРА · СЛОИ

Три слоя: голова, середина, хвост

ГОЛОВА

regex + правила +
словари

частые и простые
запросы; мгновенно,
прозрачно, дёшево

низкая увер.

СЕРЕДИНА

CRF и аналоги

token-level: BIO и
другие схемы, либо
переход к span-level
разметке

низкая увер.

ХВОСТ

трансформеры +
LLM **ИЛИ** RNN

edge-cases, которые
не решаются
правилами и обычной
NER-моделью

ВЫВОД Каскад по уверенности: 90% трафика решают дешёвые слои, тяжёлые модели работают только там, где реально нужны.

ИДЕЯ · МАРКОВСКАЯ МОДЕЛЬ

Марковская цепь для атрибутов

ВЫВОД По предыдущему токenu предсказываем тип следующего: после «16» вероятнее всего «гб» — значит, это memory.



attributes: {«memory»: «16 гб»} — юнит восстановлен из контекста, даже если пользователь его не дописал

- 1 Обучаем переходы $P(t_{i+1} | t_i)$ на миллионах запросов — бесплатная статистика.
- 2 Число без юнита перестаёт быть загадкой: «16» перед «гб» — память, перед «дюймов» — диагональ.
- 3 Дёшево, интерпретируемо, работает в голове каскада рядом с правилами.

ИДЕЯ · РАЗМЕТКА MATCH

Match 0/1: запрос попал в карточку?

ВЫВОД 100+ пар размечаем руками: 1 — клик полностью соответствует запросу, 0 — иначе. Модель доразмечает остальное.

Что это даёт

- 1 «Хорошие запросы» — кандидаты на улучшение NER: запрос $\approx$ описанию карточки.
- 2 Чистим шум: «искал айфон → кликнул чехол» не портит обучение.
- 3 На метке 1 учим $\text{embed}(\text{query}) \approx \text{embed}(\text{title} + \text{desc})$: описание дотаскивает цвет, память, синонимы.

Как это работает

1. Обучаем бустинг (CatBoost / XGBoost) на 100+ ручных метках 0/1



2. Модель проставляет $\text{match} = 1/0$ на большой объём пар $\text{query} \leftrightarrow \text{SKU}$



3. Где $\text{match} = 1$ — берём $\text{title} + \text{description}$ карточки для реранка и обогащения

CRF на слабой BIO-разметке: где мы сейчас

ВЫВОД Метрики на серебряных метках оптимистичны — это ориентир, а не финальная оценка. Нужен золотой набор 3000–5000 запросов, размеченный вручную.

Быстрый тест на выборке

Token accuracy	0.89
Entity micro-F1	0.85
F1 BRAND	0.95
F1 CATEGORY	0.78
F1 ATTR	0.85

Что это значит

- 1** BRAND учится легко (0.95) — словарь почти решает задачу в голове каскада.
- 2** CATEGORY слабее (0.78) — формулировки разнообразнее, тут нужен либо трансформер, либо больше слабо-размеченных данных.
- 3** Итог: CRF — рабочая середина каскада, но категорию и хвост дотягиваем следующим слоем.

МЕТРИКИ · КАК СЧИТАЛИ

Две метрики: по токенам и по сущностям

ВЫВОД Token accuracy мягкая — считает каждое слово. Entity-F1 строгая — сущность засчитана, только если совпали и границы, и тип. F1 честнее для NER.

Token accuracy

Доля токенов с верным BIO-тегом:

$$\text{acc} = \frac{\# \text{верных тегов}}{\# \text{всех токенов}}$$

Entity-level F1 (span-match)

Сущность = точное совпадение (тип, начало, конец).

Считаем TP / FP / FN по спанам:

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}$$

$$F_1 = \frac{2PR}{P + R}$$

Пример: «ноутбук asus 16 гб»

эталон: **ноутбук**/CAT · **asus**/BRAND · **16**
гб/ATTR

CRF: **ноутбук**/CAT · **asus**/BRAND · **16**/ATTR

TP=2 (CAT, BRAND), FN=1 (ATTR-span не
совпал: «16» ≠ «16 гб»)

$$P = 1.0, \quad R = 0.67, \quad F_1 = 0.8$$

micro-F1 — суммируем TP/FP/FN по всем классам;

МЕТРИКИ · КАК ПОЛУЧИЛИ

Откуда взялись 0.89 / 0.85

ВЫВОД Обучили CRF на 80% слабо-размеченных запросов, проверили на отложенных 20%. Это оценка «CRF vs правила», а не vs истина — поэтому цифры оптимистичны.

Пайплайн замера

- 1 Слабая разметка ставит BIO-теги правилами + словарями (это «серебро»).
- 2 Берём запросы с ≥ 1 сущностью, делим **80/20** (train_test_split, seed=42).
- 3 CRF (sklearn-crfsuite, L-BFGS, 80 итераций) учится на 80%.
- 4 Предсказываем теги на 20% и сравниваем со слабыми метками того же теста.

Почему такие числа

- 1 **BRAND 0.95** — бренды из словаря, CRF легко повторяет чёткий паттерн.
- 2 **CATEGORY 0.78** — категории разнообразнее и длиннее, границы span-а плывут.
- 3 **ATTR 0.85** — числовые атрибуты ловятся regex-ом стабильно.
- 4 **Оговорка:** тест — те же авто-метки, что и train $\Rightarrow$ измеряем «повторил ли CRF правила», верхняя граница. Честная оценка — только на ручном gold.

ОБНОВЛЕНИЕ · РАЗМЕТКА

Что уже работает: лемматизация запросов

ВЫВОД Подключили лемматизацию (Natasha) — словарь теперь ловит любые словоформы: «холодильникАМИ», «краснУЮ», «стиральнУЮ машинУ».

Что улучшили

- 1 Лемматизация: «холодильникАМИ» → «холодильник» — категория находится, даже если склонена. Прямо чинит слабый CATEGORY-recall.
- 2 Атрибутов `rehex` стало **18** вместо 7: память, размер, мощность, ток, вес, объём, частота, гарантия и др.
- 3 Расклейка склеек: «16гб» → «16 гб», спаны атрибутов теперь точные.

Пример разбора

запрос: «стиральную машину haier белую»

→ brand: **Haier**

→ category: **стиральная машина**

→ attributes: {color: **белую**}

Как держим SLA < 100 мс с лемматизацией

ВЫВОД Нейромодель Natasha грузится 1 раз при старте (~1 с), а сам разбор запроса — **<1 мс**. Онлайн-лемматизация в SLA укладывается, но голову трафика кэшируем.

Замеры (наш семпл)

Загрузка модели (старт)	~965 мс
Лемматизация 1 запроса	~0.6 мс
Токенизация	0.007 мс
Бюджет SLA	100 мс

Модель загружается один раз при инициализации сервиса, а не на каждый запрос — поэтому старт не влияет на латентность ответов.

Что планируем кэшировать

- 1 Леммы словарей** — считаем один раз офлайн при сборке лейблера, а не на каждый запрос.
- 2 Результат по запросу** (LRU-кэш): голова трафика — это одни и те же запросы; 90% кликов дают лишь 60% уникальных строк.
- 3 Леммы токенов** — кэш «словоформа → лемма»: слова повторяются, второй раз не считаем.
- 4 Фолбэк:** без Natasha «голова» каскада (regex + словарь) работает — деградируем мягко.

РИСКИ · ЧЕСТНО

Подводные камни и что с ними делать

Риск	Последствие	Меры снижения
«Соответствие» размыто	«dyson» → пылесос Dyson: 1 или 0?	жёсткий гайд разметки до старта
100 примеров маловато	модель выучит шум выборки	300–700 меток в день + согласие
Самореференция	ошибки размножаются на своих метках	holdout gold вне авторазметки
Путаница с NER	это query↔SKU, не BIO на словах	отдельные пайплайны и метрики

Каждый риск закрыт конкретной мерой снижения ещё до старта разметки.

ПЛАН · ДАЛЬШЕ

План разметки и следующие шаги

Разметка

- 1 Каждый день от каждого в команде: 300–700 пар вручную.
- 2 Остальное — автоматика: правила, алгоритмы, ИИ-агенты с выборочной проверкой глазами.
- 3 Gold-holdout откладываем сразу и не трогаем до финальной оценки.

Следующие шаги

- 4 Марковская модель атрибутов → в голову каскада.
- 5 CRF на середину, сравнение BIO vs span-level.
- 6 Матч-модель (бустинг) на первых 100+ метках → серебряные метки → реранк с описанием карточки.

ВЫВОД К защите: каскад с покрытием edge-cases + честные метрики на ручном gold, а не self-check словаря.

Спасибо!

Вопросы, критика гипотез и споры про слои — welcome.

Команда:

Новицкий Никита · @n.novitskiy

Борисов Никита · @n.borisov

Засухина Елизавета · @e.zasukhina

Олейников Александр · @a.oleynikov