

ДЕНЬ 02 · БУТКЕМП М.ВИДЕО · NLP / SEARCH

# EDA, гипотезы и слоистый NER

Что мы увидели в 31 млн кликов, какие гипотезы подтвердились, и почему задача кейса — не «обычный NER», а максимум покрытия edge-cases.

Intelligent Search · Query Understanding

## ДЕНЬ 02 · ИТОГИ

# Что сделали сегодня

**ВЫВОД** EDA закрыт, гипотезы проверены на данных, архитектура решения переосмыслена под edge-cases.

### 1 EDA

31 млн кликов, 1.79 млн запросов: длины, топы, цены, позиции, схожести.

### 2 Гипотезы

Сформулировали и проверили: что подтвердилось, а что нет.

### 3 Слои NER

Правила → CRF → трансформеры: вероятностное пространство, а не один молоток.

### 4 Разметка

План ручной разметки match 0/1 и марковская модель для атрибутов.

ДАННЫЕ · МАСШТАБ

## С чем работаем

**ВЫВОД** Данных достаточно и для словарей, и для обучения: узкое место не объём, а качество меток.

**30.99 млн**

кликов: запрос → SKU  
(query\_clicks.parquet)

**1.79 млн**

уникальных запросов

**1.18 млн**

карточек title + description  
(sku\_desc.parquet)

**333 тыс**

уникальных SKU в кликах

**7 150**

брендов


**546 тыс**

офферов в YML-каталоге (6 963  
категории)

### Пример строки клика

query: «galaxy s25»  
sku: Смартфон Samsung Galaxy  
S25 FE 8/256GB Black  
brand: Samsung · price: 50 703  
₽ · position: 2


# Запросы короткие и категорийные



**ВЫВОД** Голова трафика — категории без бренда: «стиральная машинка», «холодильники», «аэрогриль».

- 1 Медианная длина запроса  $\approx$  15–17 символов, 1–3 токена.
- 2 В топ-15 нет атрибутов: люди уточняют фильтрами или кликами.
- 3 Категорию надо ловить идеально — самый частый факт.


# Бренды: голова мощная, хвост длинный



**ВЫВОД** Топ-15 брендов покрывает огромную долю кликов, но хвост из 7 тысяч брендов правилами не закрыть.

- 1 Apple, Samsung, Haier, Xiaomi — лидеры кликов.
- 2 Цены с тяжёлым хвостом: медиана 16 тыс. ₽, средняя 31 тыс. ₽.
- 3 Словарь брендов — сильный, но конечный: нужен слой для редких написаний.

# Клики живут в топе выдачи




**ВЫВОД** Медианная позиция клика — 4. Ошибка разбора запроса почти гарантированно теряет клик.

- 1 75% кликов — в первых 16 позициях.
- 2 Позиция клика — полезный сигнал качества пары  $query \leftrightarrow SKU$  (пригодится для разметки match).
- 3 Связь цены и позиции слабая: дорогие товары кликают и в топе, и глубоко.

EDA · КЛЮЧЕВОЙ ИНСАЙТ

# 73% брендов нет в тексте запроса


Где находится бренд: запрос vs карточка клика



**ВЫВОД** Только в **27%** кликов бренд написан в запросе. В **73%** бренд известен лишь у карточки — одним словарём его не достать.

- 1 Отсюда обязателен слой **бренд-классификатора** по кликам: «айфон 15» → Apple, хотя слова «Apple» нет.
- 2 Клики — не мусор, а обучающий сигнал: самый частый бренд запроса даёт метку без ручной разметки.
- 3 Ограничение: **17%** запросов кликают  $\geq 2$  бренда — берём частотный с весом по позиции.

# Запрос короткий, но границы важны



**ВЫВОД** Медиана 2 токена, 90% запросов  $\leq 4$  слов, 99%  $\leq 8$  слов — CRF летает на CPU под SLA.

- 1 Перцентили длины: половина запросов  $\leq 2$  слов, 9 из 10  $\leq 4$ , почти все (99%)  $\leq 8$ .
- 2 Слабая разметка даёт  $\geq 1$  сущность у **~80%** запросов: BRAND ~46%, CATEGORY ~59%, ATTR ~7%.
- 3 У **~27%** запросов есть I-\* — многословные сущности, нужны именно границы span (BIO).





## EDA · ПРОВЕРКА ГИПОТЕЗ

## Гипотезы: что подтвердилось

| Гипотеза                                              | Статус     | Комментарий                      |
|-------------------------------------------------------|------------|----------------------------------|
| Н1. Запросы — короткие категорийные интенды           | Да         | топы — чистые категории          |
| Н2. Клики концентрируются в топе выдачи               | Да         | медиана позиции = 4              |
| Н3. Бренд в запросе $\Rightarrow$ клик того же бренда | В основном | heatmap диагональна              |
| Н4. Цена сильно влияет на позицию клика               | Нет        | hexbin: связь слабая             |
| Н5. Атрибуты пишут единообразно                       | Нет        | «16гб», «16 gb», «16 ГБ»         |
| Н6. Бренд обычно написан в запросе                    | Нет        | только 27% — нужен классификатор |

Красное = подтверждено данными. Н5 — главный аргумент за вероятностный подход: атрибуты не закрыть одним regex.

# Н1: запросы короткие и категорийные





**ВЫВОД** Медиана длины запроса — **17 символов** ( $\approx 1-3$  слова), а в топе — чистые категории без бренда и атрибутов.

- 1 Распределение длины (сверху) собрано в районе 10–20 символов — люди пишут коротко.
- 2 Топ запросов (снизу): «стиральная машинка», «холодильники», «аэрогриль» — это категории, а не модели.
- 3 Значит категорию надо ловить идеально: это самый частый и самый короткий факт в запросе.

## ДОКАЗАТЕЛЬСТВО · Н2

## Н2: клики концентрируются в топе




**ВЫВОД** Медиана позиции клика — **4**, а первые позиции забирают львиную долю: ошибка разбора почти гарантированно теряет клик.

- 1 Распределение позиций (сверху) резко смещено влево — кликают по верхним строкам выдачи.
- 2 Накопленная доля (снизу):  $\approx 75\%$  кликов приходится на первые 16 позиций.
- 3 Вывод для нас: точность разбора запроса прямо конвертируется в клик — промах отправляет товар вниз, куда не смотрят.

# Что нашли, когда прочитали данные руками

Полнота карточки в кликах



**ВЫВОД** Датасет собирал человек — в нём есть системные дыры и ошибки. Их надо чистить до обучения, иначе модель учится на мусоре.

- 1 Только **72%** кликов имеют полную карточку (бренд + название + цена).
- 2 У **22%** карточка вообще не подтянулась — пусты и бренд, и название (join не срослось при сборке).
- 3 Формальных NaN нет — дыры спрятаны в пустых строках "", их легко не заметить.

## КАЧЕСТВО ДАННЫХ · ПЕРЕПУТАННЫЕ КОЛОНКИ

# Артикул уехал в поле бренда

**ВЫВОД** В 66 строках **бренд — это просто число**. В 98,5% случаев это артикул из середины названия, попавший не в ту колонку.

| Название товара (sku_name)              | Поле «бренд» | Реальность |
|-----------------------------------------|--------------|------------|
| Вентилятор напольный 27942 GL 8112      | 27942        | артикул    |
| Камера видеонаблюдения 360 V380 Pro APP | 360          | артикул    |
| Туфли женские 0 Туфли                   | 0            | заглушка   |
| Бритва 4088 Extra Smooth Embrace        | 4088         | артикул    |

Правило для нас: числовой sku\_brand\_name — не бренд, а шум. Реальный бренд ищем в тексте названия либо считаем, что его нет.

# Транслит, смесь языков и омоглифы

Масштаб проблем данных (% от семпла)



**ВЫВОД** 35% уникальных запросов — смесь кириллицы и латиницы. Модель обязана быть устойчива к раскладке.

| Тип       | Пример из данных                       |
|-----------|----------------------------------------|
| Смесь     | «iPhone 17 про Макс», «bosh лодильник» |
| Транслит  | «noutbuk», «televizor», «Stiralnay»    |
| Омоглиф   | «Ресанта» (а — кир.), «Фаза»           |
| Раскладка | «dfhixvfz» → «варочная»                |

## КАЧЕСТВО ДАННЫХ · ЗАБЫТАЯ РАСКЛАДКА

## Печатали по-русски в EN-раскладке

**ВЫВОД** Нашли **80+** запросов вида dfhjxyfz gfytkm — это «варочная панель», набранное в латинской раскладке. Поиск обязан их авто-исправлять.

|                                                 |                                                  |                                                |
|-------------------------------------------------|--------------------------------------------------|------------------------------------------------|
| lkz djkc aty gkjqr f gkjqr f → <b>для волос</b> | dcnhfbbdftvsq [jkljlbkmybr → <b>встраиваемый</b> | rkfdbfnehf buhjfdz → <b>клавиатура игровая</b> |
| <b>фен</b> <b>плойка</b> <b>плойка</b>          | <b>холодильник</b>                               |                                                |
| pfhzlyst ecnhjqcndf lkz frrevkjnjhd             | dcnhjtyyfz gjceljvjqr f → <b>встроенная</b>      | rjkjyrb rjvgm.nthyst → <b>колонки</b>          |
| fdnj → <b>зарядные устройства</b>               | <b>для посудомойка</b>                           | <b>компьютерные</b>                            |
| <b>аккумуляторов авто</b>                       |                                                  |                                                |
| dfhjxyfz gfytkm ,tkjt cntrkh → <b>варочная</b>  | dcnhjtyysq [jkljlbkmybr → <b>встроенный</b>      | rjv,bybhjdfyyfz gkbnf → <b>комбинированная</b> |
| <b>панель белое</b> <b>стекл</b>                | <b>холодильник</b>                               | <b>плита</b>                                   |
| dbltjrfvthf lkz gjvtotybz → <b>видеокамера</b>  | ufpjdfz gkbnf → <b>газовая плита</b>             | rjvgm.nthyst rjkjyrb → <b>компьютерные</b>     |
| <b>для помещения</b>                            |                                                  | <b>колонки</b>                                 |
| dcnhfbdftvfz cnbhfkmyfz                         | ufqrjdthn htldthu → <b>гайковерт редверг</b>     | rjat pthyjdjq → <b>кофе зерновой</b>           |
| vfiby f → <b>встраиваемая</b>                   |                                                  |                                                |
| <b>машина</b>                                   | <b>стиральная</b>                                |                                                |
| le[jdj q irfa 'ktrnhbxtcrbq → <b>духовой</b>    | ukflbkmyfz ljcrf → <b>гладильная доска</b>       | rhtckj rjvgm.nthyjt → <b>кресло</b>            |
| <b>шкаф электрический</b>                       |                                                  | <b>компьютерное</b>                            |
| pfhzlyjt ecnhjqcndj czjvb → <b>зарядное</b>     | lhtkm ,eh → <b>дрель бур</b>                     | vbrhjdjkyjdrf rfhhthf → <b>микроволновка</b>   |
| <b>устройство сями</b>                          |                                                  | <b>карьер</b>                                  |
| rf,tkm lkz rkfdbfnehs → <b>кабель</b>           | pfdfhjxysq xfqybr → <b>заварочный чайник</b>     | vbrhjdjkyjdrf njib,f → <b>микроволновка</b>    |
| <b>клавиатуры</b>                               |                                                  | <b>тошиба</b>                                  |

## КАЧЕСТВО ДАННЫХ · ДУБЛИ И МЕРЫ

# Дубли брендов и что мы с этим делаем

## Один бренд — много написаний

| Проблема    | Пример                        |
|-------------|-------------------------------|
| Регистр     | APPLE / Apple, honor / HONOR  |
| Перевод     | Stinol / Стинол, KION / КИОН  |
| Дубли строк | один клик записан по 2–3 раза |

## Меры (слой нормализации)

- 1 Приводим бренды к канону: регистр, транслит, схлопывание дублей (**Стинол**=**Stinol**).
- 2 Фильтруем мусор до обучения: пустые карточки и цена  $\leq 0$  — вон или в отдельную метку.
- 3 Позиция = 0 — это «нет данных», не топ выдачи; не используем как сигнал.
- 4 Это прямой аргумент за **H5**: одним regex единообразие не навести.

205 групп брендов различаются лишь регистром/пробелами, ~209 групп — кандидаты на омоглифы.



## ПОСТАНОВКА · ПЕРЕОСМЫСЛЕНИЕ

# Задача — не «обычный NER»

**ВЫВОД** Главная цель — максимизировать покрытие edge-cases, а не выбить красивый F1 на простых запросах.

### Почему так

- 1 Голова запросов решается словарём за день — это не подвиг.
- 2 Конверсию теряют хвосты: опечатки, редкие бренды, склейки, смесь языков.
- 3 Ценность решения = сколько хвоста мы покрываем при  $SLA < 100$  мс.

### Работаем в вероятностном пространстве

Каждый слой отдаёт не только ответ, но и уверенность. Если уверенность низкая — запрос уходит на слой тяжелее. Так простое остаётся быстрым, а сложное — решаемым.

## АРХИТЕКТУРА · СЛОИ

## Три слоя: голова, середина, хвост



**ВЫВОД** Каскад по уверенности: 90% трафика решают дешёвые слои, тяжёлые модели работают только там, где реально нужны.

## ИДЕЯ · МАРКОВСКАЯ МОДЕЛЬ

## Марковская цепь для атрибутов

**ВЫВОД** По предыдущему токenu предсказываем тип следующего: после «16» вероятнее всего «гб» — значит, это memory.



attributes: {«memory»: «16 гб»} — юнит восстановлен из контекста, даже если пользователь его не дописал

- 1 Обучаем переходы  $P(t_{i+1} | t_i)$  на миллионах запросов — бесплатная статистика.
- 2 Число без юнита перестаёт быть загадкой: «16» перед «гб» — память, перед «дюймов» — диагональ.
- 3 Дёшево, интерпретируемо, работает в голове каскада рядом с правилами.

## ИДЕЯ · РАЗМЕТКА MATCH

# Match 0/1: запрос попал в карточку?

**ВЫВОД** 100+ пар размечаем руками: 1 — клик полностью соответствует запросу, 0 — иначе. Модель доразмечает остальное.

## Что это даёт

- 1 «Хорошие запросы» — кандидаты на улучшение NER: запрос  $\approx$  описанию карточки.
- 2 Чистим шум: «искал айфон → кликнул чехол» не портит обучение.
- 3 На метке 1 учим  $\text{embed}(\text{query}) \approx \text{embed}(\text{title} + \text{desc})$ : описание дотаскивает цвет, память, синонимы.

## Как используем скор

NER достал факты → фильтр и буст в выдаче



$P(\text{match} = 1 \mid \text{query}, \text{sku\_text})$  — перанк  
поверх



модель: градиентный бустинг (CatBoost / XGBoost) на простых признаках

# CRF на слабой BIO-разметке: где мы сейчас

**ВЫВОД** Метрики на серебряных метках оптимистичны — это ориентир, а не финальная оценка. Нужен золотой набор 3000–5000 запросов, размеченный вручную.

## Быстрый тест на выборке

|                 |             |
|-----------------|-------------|
| Token accuracy  | <b>0.89</b> |
| Entity micro-F1 | <b>0.85</b> |
| F1 BRAND        | <b>0.95</b> |
| F1 CATEGORY     | <b>0.78</b> |
| F1 ATTR         | <b>0.85</b> |

## Что это значит

- 1** BRAND учится легко (0.95) — словарь почти решает задачу в голове каскада.
- 2** CATEGORY слабее (0.78) — формулировки разнообразнее, тут нужен либо трансформер, либо больше слабо-размеченных данных.
- 3** Итог: CRF — рабочая середина каскада, но категорию и хвост дотягиваем следующим слоем.

## РИСКИ · ЧЕСТНО

# Подводные камни и что с ними делать

| Риск                   | Последствие                         | Меры снижения                   |
|------------------------|-------------------------------------|---------------------------------|
| «Соответствие» размыто | «dyson» → пылесос Dyson: 1 или 0?   | жёсткий гайд разметки до старта |
| 100 примеров маловато  | модель выучит шум выборки           | 300–700 меток в день + согласие |
| Самореференция         | ошибки размножаются на своих метках | holdout gold вне авторазметки   |
| Путаница с NER         | это query↔SKU, не BIO на словах     | отдельные пайплайны и метрики   |

*Каждый риск закрыт конкретной мерой снижения ещё до старта разметки.*

## ПЛАН · ДАЛЬШЕ

# План разметки и следующие шаги

## Разметка

- 1 Каждый день от каждого в команде: 300–700 пар вручную.
- 2 Остальное — автоматика: правила, алгоритмы, ИИ-агенты с выборочной проверкой глазами.
- 3 Gold-holdout откладываем сразу и не трогаем до финальной оценки.

## Следующие шаги

- 4 Марковская модель атрибутов → в голову каскада.
- 5 CRF на середину, сравнение BIO vs span-level.
- 6 Матч-модель (бустинг) на первых 100+ метках → серебряные метки → реранк с описанием карточки.

**ВЫВОД** К защите: каскад с покрытием edge-cases + честные метрики на ручном gold, а не self-check словаря.

# Спасибо!

Вопросы, критика гипотез и споры про слои — welcome.

## Команда:

Новицкий Никита · @n.novitskiy

Борисов Никита · @n.borisov

Засухина Елизавета · @e.zasukhina

Олейников Александр · @a.oleynikov