

ДЕНЬ 02 · БУТКЕМП М.ВИДЕО · NLP / SEARCH

EDA, гипотезы и слоистый NER

Что мы увидели в 31 млн кликов, какие гипотезы подтвердились, и почему задача кейса — не «обычный NER», а максимум покрытия edge-cases.

Intelligent Search · Query Understanding

ДЕНЬ 02 · ИТОГИ

Что сделали сегодня

ВЫВОД EDA закрыт, гипотезы проверены на данных, архитектура решения переосмыслена под edge-cases.

1 EDA

31 млн кликов, 1.79 млн запросов: длины, топы, цены, позиции, схожести.

2 Гипотезы

Сформулировали и проверили: что подтвердилось, а что нет.

3 Слои NER

Правила → CRF → трансформеры: вероятностное пространство, а не один молоток.

4 Разметка

План ручной разметки match 0/1 и марковская модель для атрибутов.

ДАННЫЕ · МАСШТАБ

С чем работаем

ВЫВОД Данных достаточно и для словарей, и для обучения: узкое место не объём, а качество меток.

30.99 млн

кликов: запрос → SKU
(query_clicks.parquet)

1.79 млн

уникальных запросов

1.18 млн

карточек title + description
(sku_desc.parquet)

333 тыс

уникальных SKU в кликах

7 150

брендов


546 тыс

офферов в YML-каталоге (6 963
категории)

Пример строки клика

query: «galaxy s25»
sku: Смартфон Samsung Galaxy
S25 FE 8/256GB Black
brand: Samsung · price: 50 703 ₽
· position: 2


Запросы короткие и категорийные



ВЫВОД Голова трафика — категории без бренда: «стиральная машинка», «холодильники», «аэрогриль».

- 1 Медианная длина запроса $\approx$ 15–17 символов, 1–3 токена.
- 2 В топ-15 нет атрибутов: люди уточняют фильтрами или кликами.
- 3 Категорию надо ловить идеально — самый частый факт.


Бренды: голова мощная, хвост длинный



ВЫВОД Топ-15 брендов покрывает огромную долю кликов, но хвост из 7 тысяч брендов правилами не закрыть.

- 1 Apple, Samsung, Haier, Xiaomi — лидеры кликов.
- 2 Цены с тяжёлым хвостом: медиана 16 тыс. ₽, средняя 31 тыс. ₽ — premium тянет вправо.
- 3 Словарь брендов — сильный, но конечный инструмент: нужен слой для редких написаний.

Клики живут в топе выдачи



ВЫВОД Медианная позиция клика — 4. Ошибка разбора запроса почти гарантированно теряет клик.

- 1 75% кликов — в первых 16 позициях.
- 2 Позиция клика — полезный сигнал качества пары $query \leftrightarrow SKU$ (пригодится для разметки match).
- 3 Связь цены и позиции слабая: дорогие товары кликают и в топе, и глубоко.

EDA · ПРОВЕРКА ГИПОТЕЗ

Гипотезы: что подтвердилось

Гипотеза	Статус	Комментарий
H1. Большинство запросов — короткие категорийные интенты	да	топы — чистые категории
H2. Клики концентрируются в топе выдачи	да	медиана позиции = 4
H3. Бренд в запросе $\Rightarrow$ клик по тому же бренду	в основном	heatmap query $\times$ brand диагональна
H4. Цена сильно влияет на позицию клика	нет	hexbin: связь слабая
H5. Атрибуты в запросах пишут единообразно	нет	«16гб», «16 gb», «16 ГБ» — зоопарк

ВЫВОД H5 — главный аргумент за вероятностный подход: атрибуты нельзя закрыть одним regex.

ПОСТАНОВКА · ПЕРЕОСМЫСЛЕНИЕ

Задача --- не «обычный NER»

ВЫВОД Главная цель — максимизировать покрытие edge-cases, а не выбить красивый F1 на простых запросах.

Почему так

- 1 Голова запросов решается словарём за день — это не подвиг.
- 2 Конверсию теряют хвосты: опечатки, редкие бренды, склейки, смесь языков.
- 3 Ценность решения = сколько хвоста мы покрываем при $SLA < 100$ мс.

Работаем в вероятностном пространстве

Каждый слой отдаёт не только ответ, но и уверенность. Если уверенность низкая — запрос уходит на слой тяжелее. Так простое остаётся быстрым, а сложное — решаемым.

АРХИТЕКТУРА · СЛОИ

Три слоя: голова, середина, хвост




ВЫВОД Каскад по уверенности: 90% трафика решают дешёвые слои, тяжёлые модели работают только там, где реально нужны.

ИДЕЯ · МАРКОВСКАЯ МОДЕЛЬ

Марковская цепь для атрибутов

ВЫВОД По предыдущему токenu предсказываем тип следующего: после «16» вероятнее всего «гб» — значит, это memory.



- 1 Обучаем переходы $P(t_{i+1} | t_i)$ на миллионах запросов — бесплатная статистика.
- 2 Число без юнита перестаёт быть загадкой: «16» перед «гб» — память, перед «дюймов» — диагональ.
- 3 Дёшево, интерпретируемо, работает в голове каскада рядом с правилами.

attributes: {«memory»: «16 гб»} — юнит восстановлен из контекста, даже если пользователь его не дописал

ИДЕЯ · РАЗМЕТКА MATCH

Match 0/1: запрос попал в карточку?

ВЫВОД 100+ пар размечаем руками: 1 — клик полностью соответствует запросу, 0 — иначе. Модель доразмечает остальное.

Что это даёт

- 1 «Хорошие запросы» — кандидаты на улучшение NER: запрос $\approx$ описанию карточки.
- 2 Чистим шум: «искал айфон → кликнул чехол» не портит обучение.
- 3 На метке 1 учим $\text{embed}(\text{query}) \approx \text{embed}(\text{title} + \text{desc})$: описание дотаскивает цвет, память, синонимы.

Как используем скор

NER достал факты → фильтр и буст в выдаче

$P(\text{match} = 1 \mid \text{query}, \text{sku_text})$ —
реранк поверх

модель: градиентный бустинг
(CatBoost / XGBoost) на простых фи-
чах

РИСКИ · ЧЕСТНО

Подводные камни и что с ними делать

Риск	Почему больно	Решение
«Полное соответствие» размыто 100 примеров маловато	«dyson» → пылесос Dyson — это 1 или 0? модель выучит шум выборки	жёсткий гайд разметки с примерами до старта 300–700 меток в день с каждого + проверка согласия
Самореференция	модель учится на своих же метках, ошибки размножаются	holdout gold, который модель никогда не размечала
Путаница с NER	это про query↔SKU, не про BIO на словах	отдельные пайплайны, отдельные метрики

ВЫВОД Каждому риску — конкретный процесс, а не «будем аккуратнее».

ПЛАН · ДАЛЬШЕ

План разметки и следующие шаги

Разметка

- 1 Каждый день от каждого в команде: 300–700 пар вручную.
- 2 Остальное — автоматика: правила, алгоритмы, ИИ-агенты с выборочной проверкой глазами.
- 3 Gold-holdout откладываем сразу и не трогаем до финальной оценки.

Следующие шаги

- 4 Марковская модель атрибутов → в голову каскада.
- 5 CRF на середину, сравнение BIO vs span-level.
- 6 Матч-модель (бустинг) на первых 100+ метках → silver labels → перанк с description.

ВЫВОД К защите: каскад с покрытием edge-cases + честные метрики на ручном gold, а не self-check словаря.

Спасибо!

Вопросы, критика гипотез и споры про слои — welcome.

Команда:

Новицкий Никита · @n.novitskiy

Борисов Никита · @n.borisov

Засухина Елизавета · @e.zasukhina

Олейников Александр · @a.oleynikov