

ДЕНЬ 03 · БУТКЕМП М.ВИДЕО · NLP / SEARCH

Глубокий EDA и первый MVP

Предобработка, тег MODEL, разбор схем разметки, рабочий каскад моделей и два готовых приложения: умный поиск и разметка для команды.

Умный поиск · Понимание запроса · MVP

ДЕНЬ 03 · ИТОГИ

Что собрали ко Дню 3

КОРОТКО За день прошли путь от анализа данных до работающего продукта: единая предобработка, новый тег MODEL, каскад из трёх обученных моделей и два настольных приложения.



Предобработка

чистка, расклейка
склеек, словарь
моделей на 6130 фраз



Схемы разметки

разобрали IO, BIO,
BILOU — храним
спаны, учим на BIO



Модели MVP



классификатор
бренда, CRF,
марковский типизатор



Приложения

умный поиск +
разметка для
команды (3 сборки)

С чем работаем: масштаб и длины



Вывод Запросы очень короткие: половина — 2 токена, 99% укладываются в 7. Это задача понимания запроса, а не разбора длинного документа.

- 1 30,99 млн кликов, 1,18 млн карточек. В семпле 200 тысяч строк — 49 тысяч уникальных запросов и 3,1 тысячи брендов.
- 2 Длина в токенах: медиана 2, у 90% — до 4, у 99% — до 7. В символах: 17 и 31.
- 3 Медианная цена клика — 16 165 ₽, пропусков в ключевых полях нет.

ГЛУБОКИЙ EDA · БРЕНДЫ


73% брендов нет в тексте запроса



ГЛАВНОЕ ЧИСЛО Лишь в 27% кликов бренд написан в самом запросе. В остальных 73% бренд известен только из кликнутой карточки — словарём его не достать.

- 1 Пользователь пишет «айфон 15» — слова «Apple» нет, но купить он хочет именно Apple. Поэтому нужен классификатор бренда по всему запросу.
- 2 17% запросов кликают по двум и более брендам — берём самый частый бренд с весом по позиции клика.
- 3 Словарь и клики согласованы: где бренд есть в тексте, он совпадает с кликом в 79,5% случаев.

Слабая разметка: покрытие и границы



КАК ЧИТАТЬ Слабая разметка — это автоматические теги от словарей и правил. Она бесплатная, но шумная: на ней учим, а проверяем на ручной.

- 1 Хотя бы одну сущность получают 79,8% запросов: бренд — у 46%, категория — у 59%, атрибуты — у 7%.
- 2 У 27% запросов есть теги I — нужны именно границы спанов, а не классификация всего запроса.
- 3 Регулярки атрибутов покрывают лишь 3% запросов — нужен типизатор поверх найденного спана.

ПРЕДОБРАБОТКА · ПАЙПЛАЙН

Единый слой очистки запроса

Шесть шагов очистки

Шаг	Что делает
Базовая чистка	убирает мусорные пробелы, ё → е
Расклейка	«128гб» → «128 гб»
Сепараторы	«g-pro» → «g pro»
Нормализация	единый ключ для словарей
Защита брендов	«Красный Октябрь» — не цвет
Подсказки	спаны моделей поверх разметки

Зачем один общий слой

- 1 Раньше каждый ноутбук чистил запрос по-своему — результаты не сходились. Теперь очистка одна на всех.
- 2 Регистр сохраняем там, где он несёт смысл: «красный» — это цвет, а «Красный Октябрь» — бренд конфет.
- 3 Модуль отдаёт и чистый текст, и подсказки: где в запросе модель, а где защищённый бренд.

ЭФФЕКТ Спан модели появляется у 18% запросов, склейки чинятся у 11%, а каждый четвёртый «пустой» хвост после бренда оживает.

ПРЕДОБРАБОТКА · ПРИМЕР

Живой пример: запрос до и после

ИСХОДНЫЙ ЗАПРОС «Наушники Logitech G-Pro X SE 128гб» — дефисы, клейки, смесь языков.

Шаг 1 · расклейка и сепараторы

наушники logitech g pro x se 128 гб

«G-Pro» распался в «g pro», «128гб» — в «128 гб». Теперь словари найдут каждую часть.

Шаг 2 · разметка со словарями и подсказками

наушники · КАТЕГОРИЯ logitech · БРЕНД g pro x se · МОДЕЛЬ 128 гб · АТРИБУТ


«g pro x se» поймал словарь моделей из майнинга, «128 гб» — регулярка памяти.

Шаг 3 · готовые факты

бренд = Logitech · категория = наушники · модель = g pro x se · память = 128 ГБ.

ПРЕДОБРАБОТКА · ИЗМЕРЕНИЕ

Что даёт предобработка на семпле



КАК МЕРИЛИ Взяли 12 000 уникальных запросов и прогнали через пайплайн дважды: со словарём моделей и без него.

- 1 18% запросов получают спан модели — примерно каждый пятый.
- 2 11% содержат склейку вида «128гб», которую чинит расклейка.
- 3 24% пустых хвостов после бренда получают тег модели после подсказок.
- 4 Защита брендов срабатывает у 4,5% — редко, но спасает «Красный Октябрь» от превращения в цвет.

ТЕГ MODEL · ПРОБЛЕМА

Хвост после бренда теряется



ПРОБЛЕМА После бренда часто идёт название линейки — «dyson v15», «galaxy s24». При слабой разметке эти слова остаются без тега, и CRF не может их выучить.

- 1 Из 15 тысяч запросов бренд есть у 7046. Почти у половины (46%) после бренда остался неразмеченный латинский хвост.
- 2 Типичная длина хвоста — два токена: «zenbook a16», «ipad air».
- 3 Это не атрибут — нет числа с единицей. Нужен отдельный тег MODEL и словарь линеек.

ТЕГ MODEL · ПРИМЕРЫ

Как выглядят потерянные хвосты

ДО СЛОВАРЯ Серые слова — то, что разметка не смогла объяснить. Именно они и есть модели.

До: хвост без тега

пылесос dyson v15
телефон samsung galaxy s24
asus zenbook a16
apple ipad air

После: словарь линеек подключён

пылесос dyson v15 · МОДЕЛЬ
телефон samsung galaxy s24 · МОДЕЛЬ
asus zenbook a16 · МОДЕЛЬ
apple ipad air · МОДЕЛЬ

ЧТО ИЗМЕНИЛОСЬ Хвост после бренда перестал быть «мусором» — теперь это полноценный факт «модель», по которому можно искать и ранжировать.

Майнинг словаря: пример «g pro»

ИДЕЯ Названия кликнуток уже содержат модели. Находим в названии бренд — и всё, что идёт после него, считаем кандидатом в модели.

Название кликнутки → кандидаты

Наушники **Logitech** **G** **PRO** **X** **SE** Black

После бренда снимаем 1–4 коротких токена:


Кандидат	Раз
g	213
g pro	87
g pro x	31
g pro x se	9
g pro x se black	2 — отсеки

Почему порог — 6 раз

- 1 Фраза попадает в словарь, если встретилась **минимум 6 раз**. «g pro» видели 87 раз — берём. «g pro x se black» — два раза, случайный хвост, отсекаем.
- 2 Порог 2 — словарь раздувается до 7215 фраз и тащит мусор. Порог 20 — остаётся 335 фраз, теряются редкие линейки.
- 3 Шесть — золотая середина: 1512 фраз, 22% хвостов покрыто, словарь чист на 96,6%.

TEG MODEL · ПОРОГ

Выбор порога: размер словаря против покрытия




КАК ЧИТАТЬ ГРАФИК Чёрная кривая — размер словаря, красная — доля хвостов, которые он покрывает. Пунктир — наш выбор.

- 1** Из 47 тысяч названий карточек намайнили 8540 сырых кандидатов: galaxy, iphone, watch, redmi и другие.
- 2** Кривые расходятся плавно, «локтя» нет — выбрали порог 6 как компромисс между размером и покрытием.
- 3** Дополнительные фильтры: голые числа не берём; фразы из одного токена — только коды вида «v15», «g305», «ps5».

ТЕГ MODEL · РЕЗУЛЬТАТ

До и после подключения словаря



ВЫВОД Словарь линеек включает класс MODEL: было 0 запросов с тегом — стало 1573. Потерянных хвостов стало меньше на четверть.

- 1 Латинские хвосты без тега: 3262 → 2502, минус 23%.
- 2 Проверили качество словаря вручную: 96,6% фраз — настоящие линейки, остальное — длинные артикулы и аксессуары, их вычистим.
- 3 Оставшиеся хвосты словарём не закрыть — это кандидаты на ручную разметку, для неё мы сделали приложение (покажем дальше).

РАЗМЕТКА · СХЕМЫ

Какие бывают схемы токен-разметки

КОНТЕКСТ Задача NER — найти спаны сущностей. Но модели классифицируют токены, поэтому спаны кодируют в токен-схему. Разные схемы — разные способы обозначить границы.

Схема	Теги	Суть
IO	I, O	самое простое, но две соседние сущности сливаются
BIO (IOB)	B, I, O	B отмечает начало — границы видны; стандарт CoNLL
IOE	I, O, E	то же самое, только отмечается конец, а не начало
BILOU	B, I, L, O, U	добавляются теги конца (L) и одиночного слова (U)
BIES	B, I, E, S, O	максимум классов — сильнее дисбаланс, учить труднее

Общая беда всех токен-схем: вложенные сущности не выразить — «адрес» нельзя разбить на город, улицу и дом

РАЗМЕТКА · ВЫБОР

Храним спаны, учим на BIO

ВЫВОД Спаны — универсальный формат хранения и оценки: любой модельный ответ приводится к ним. BIO — формат обучения. Держим оба.

Почему именно BIO

- 1** Классы — полные теги (B-BRAND, I-ATTR и так далее). Буквы B, I, O лишь кодируют границы.
- 2** У 27% запросов сущности длиннее одного токена. Схема IO склеила бы соседние сущности в одну, BIO их разделяет.
- 3** BILOU на коротких запросах даёт больше классов без выигрыша — дисбаланс растёт, качество нет.
- 4** Наши теги: BRAND, MODEL, CATEGORY, ATTR (с приставками B и I) плюс O.

Пример BIO-разметки

ноутбук **B-CATEGORY**

asus **B-BRAND**

zenbook **B-MODEL**

16 **B-ATTR**

гб **I-ATTR**

РАЗМЕТКА · ИСТОЧНИКИ

Два сигнала сливаются в одну разметку

ИДЕЯ Текст запроса и поведение пользователей — независимые источники правды. Их слияние даёт разметку, которой не было ни в одном из них по отдельности.




Факт	Откуда сигнал
Бренд в тексте	словарь по запросу
Скрытый бренд	только клики
Категория	словарь + клики
Модель	майнинг названий карточек
Атрибуты	регулярки по тексту

MVP · АРХИТЕКТУРА

Гибридный каскад: что уже собрано

КАК УСТРОЕНО Каждый слой закрывает слабость предыдущего: правила — мгновенные, CRF понимает морфологию, классификатор достаёт скрытый бренд, цепь определяет тип атрибута. На выходе — факты за десятки миллисекунд.



ПЕТЛЯ КАЧЕСТВА неуверенные ответы и ошибки уходят в ручную разметку, на ней дообучаем CRF и пополняем словари

ПРОДАКШЕН · ПУТЬ ЗАПРОСА

Путь запроса от строки до выдачи

ЗАЧЕМ Извлечь факты — только середина пути: дальше нормализация, каталог и ранжирование.



Шаг	Пример
Нормализация	«16гб», «16 gb», «16 ГБ» — всё превращается в одно значение: 16 ГБ
Каталог	категория «ноутбук» находит узел «Ноутбуки и планшеты»
Ранжирование	карточки с брендом asus и памятью 16 ГБ идут наверх

MVP · КЛАССИФИКАТОР БРЕНДА

Silver для бренда: 67 классов, не только бренды

КЛЮЧЕВАЯ ИДЕЯ Классификатор — запасной слой, когда словарь не нашёл бренд. Он не должен отвечать на каждый запрос: на «холодильник» нельзя тыкать в частый клик-бренд. Поэтому в классы добавили NO_BRAND и UNKNOWN.



Состав silver: 65 брендов + 2 спец-класса



- 1 Из 63 тысяч агрегированных запросов в silver попали 28 664: у остальных нет надёжного сигнала — их честно выбросили, а не разметили наугад.
- 2 Уверенность метки — из кликов: клик выше в выдаче весит больше (вес $1/(1+позиция)$), майор-бренд должен набрать не меньше 55% веса.
- 3 NO_BRAND — запрос-категория без бренда («холодильник»). UNKNOWN — бренд есть, но вне топ-65 («стинол», «darina»): модель учится отказываться, а не угадывать похожий.
- 4 Разбиение: 22 846 на обучение, 5 710 на валидацию.

MVP · КЛАССИФИКАТОР БРЕНДА

Четыре модели: что и как обучали



ПОСТАНОВКА Мультикласс запрос → бренд на silver. Все четыре — линейные модели на TF-IDF: отвечают за миллисекунды, что критично для SLA. Разница — в признаках и балансировке.

Модель	Признаки	Особенность
LogReg слова+симв.	слова 1–2 + символьные n-граммы 2–4	выбрана в прод: меньше всего ложных брендов
SGD символьная	символьные n-граммы	лучший macro-F1, но чаще врёт на категориях
LogReg символьная	символьные n-граммы	базовый вариант без словных признаков
LogReg с балансом	символьные n-граммы	веса классов — хуже на редких брендах

- 1 Символьные кусочки по 2–4 буквы делают «айфон», «aфон» и «iphone» похожими — опечатки не страшны.
- 2 Обучение с весами по уверенности клика: сомнительные метки влияют меньше. Все четыре модели сохранены, сравнение — на одной валидации.

MVP · КЛАССИФИКАТОР БРЕНДА

Результаты: 0,95 macro-F1 и честные отказы




КАК ЧИТАТЬ Верх — macro-F1 до и после порогов отказа. Низ — доля запросов-категорий, где модель ошибочно навязала бренд (главная метрика, цель — ноль).

- 1 По macro-F1 SGD формально впереди (0,951 против 0,950), но разница — третий знак.
- 2 Решает вторая метрика: у LogReg слова+символы ложный бренд на категориях 6,9% против 9,4% у SGD — её и берём в прод.
- 3 F1 спец-классов: NO_BRAND 0,88, UNKNOWN 0,86 — модель научилась говорить «бренда нет» и «не знаю».
- 4 Примеры: айфон 15 про > Apple, холодильник > NO_BRAND.

MVP · КЛАССИФИКАТОР БРЕНДА

Пороги отказа: лучше пусто, чем ложный бренд



Хвост по классам: PlayStation 0,67 (4 примера), UNKNOWN 0,86, NO_BRAND 0,88 — редкие классы ждут золотой разметки.

Когда классификатор вообще зовут:

- 1 Словарь или алиас уже нашли бренд — не зовут.
- 2 Запрос — чистая категория — не зовут, бренд пустой.
- 3 Есть намёк на бренд (алиас, похожее на модель слово) — зовут.

Как принимается ответ:

- 4 Уверенность top-1 не ниже 0,42 и отрыв от top-2 не меньше 0,08 — принимаем бренд.
- 5 Ответ NO_BRAND или UNKNOWN с уверенностью выше своего порога — бренд остаётся пустым, и это правильный ответ.
- 6 Пороги не прошли — отказ, бренд пустой. С порогами точность даже растёт: отказы съедают в основном ошибки.

CRF на слабой разметке, путь к золотой

ЧЕСТНОСТЬ Числа ниже — проверка «повторила ли модель правила», поэтому они завышены. Настоящую оценку даст только ручная золотая разметка.

Быстрый тест на выборке

Точность по токенам	0,91
F1 по сущностям	0,875
F1 бренды	0,95
F1 категории	0,82
F1 атрибуты	0,85

Слабая и золотая разметка

- 1** Слабая — автоматическая, от словарей и правил: много и бесплатно, но с шумом. На ней учим.
- 2** Золотая — ручная, 300–1000 запросов со спанами моделей. На ней честно меряем.
- 3** Если и учить, и проверять на одних и тех же автоматических метках — модель просто копирует правила, а числа льстят. Отложенная золотая выборка решает это.
- 4** Дальше: переобучить CRF на разметке с тегом MODEL и свериться с золотой.

MVP · МАРКОВСКИЕ ЦЕПИ

Тип атрибута: «16 гб» — это память



16 гб > память 55 дюймов > диагональ

2 кг > вес wi-fi > связь

ЭТО БЕЙЗЛАЙН Цепь ничего не «понимает» — она запоминает частоты пар токенов. Дальше по плану — переход к RNN (следующий слайд).

1 Откуда метки? От регулярок-учителей: регулярка «число + гб» сама знает, что это память, — прогоняем её по 60 тыс. запросов и записываем тип каждой паре токенов.

2 Что запоминает цепь. Таблицу частот: пара «<число>|гб» встретилась 154 раза — все 154 раза «память». На инференсе цепь смотрит пару соседних токенов.

3 Зачем, если есть регулярка? Цепь обобщает шире: ловит пары с опечатками и перестановками, отвечает за доли миллисекунды.

MVP · ПЛАН РАЗВИТИЯ

Цепь — бейзлайн. Дальше — RNN

ЧЕСТНО О ПРЕДЕЛЕ Цепь видит только пару соседних токенов внутри спана. Контекст до спана («телевизор» или «ноутбук» перед «55») ей недоступен в принципе — это ограничение метода, а не реализации.


Что не может цепь

- ❶ «5» без единицы измерения: пара «<число>|конец» встречается в десяти типах — цепь отвечает «не знаю».
- ❷ Контекст категории: «55» после «телевизор» — почти наверняка диагональ, но цепь слова «телевизор» не видит.
- ❸ Новые единицы и опечатки: «гиг», «джиби» — если пары не было в обучении, ответа нет.

Почему RNN это закроет

- ❶ Рекуррентная сеть читает запрос целиком слева направо и несёт контекст: к моменту «55» она уже «помнит» слово «телевизор».
- ❷ Символьные эмбединги переживают опечатки: «гиг» и «гб» окажутся рядом в пространстве признаков.
- ❸ План: учим лёгкую BiLSTM на той же слабой разметке; RNN зовём только там, где цепь сказала «не знаю» (36%), — так держим латентность.

Где цепь бессильна: голое число



ПРЕДЕЛ Число без единицы измерения многозначно: «5» встречается в десяти разных типах атрибутов. Пара токенов тут не помогает — нужен контекст категории.

- 1 Нашли 27 «числовых омонимов»: «5» и «12» бывают десятью разными атрибутами, «1» — восемью.
- 2 Лестница усложнения: правила, затем цепь, затем лёгкий классификатор с учётом категории, затем RNN — только для омонимов.
- 3 Берём самый дешёвый слой, который держит время ответа, — и усложняем только там, где он ошибается.

РАЗМЕТКА · СООТВЕТСТВИЕ 1/0

Чистим шумные клики моделью

ЗАЧЕМ Клик — шумный сигнал: пользователь искал айфон, а кликнул чехол. Такие пары портят обучение. Убираем их бинарной моделью «соответствует или нет».



Пример пары

ноутбук asus 16 + ASUS VivoBook 16 > 1


ноутбук asus 16 + Чехол для MacBook > 0

1 Признаки: похожесть текста запроса и названия, совпадение бренда, позиция клика.

2 Далее доразмечаем только пары, где модель сомневается, — так разметка окупается быстрее.

Данные и стратегия разметки

ПРИНЦИП Разметку проектируем, а не «докупаем объёмом»: размечаем в первую очередь то, на чём модель ошибается или сомневается.





- 1 Активное обучение.** Размечаем то, в чём модель не уверена, — каждая метка приносит максимум пользы.
- 2 Слабая разметка.** Правила и словари дают дешёвые метки — миллионы примеров без человека.
- 3 Помощь разметчику.** Приложение показывает готовые подсказки — человек правит, а не размечает с нуля.
- 4 Золотые наборы.** Эталон для честной оценки и контроля дрейфа. Первая волна — 3×1500 запросов на троих.

ПРИЛОЖЕНИЕ · РАЗМЕТКА

Приложение разметки на C++/Qt: мастер из трёх этапов



КАК УСТРОЕНО Нативное приложение на C++ и Qt/QML. Запрос разбит на блоки по центру, фон с историей заблюрен. Этап 1: клавиши В/I/O, метка появляется над блоком, Backspace снимает и шагает назад, Enter — подтверждение этапа.



ПРИЛОЖЕНИЕ · РАЗМЕТКА

Подтипы атрибутов и режим 1/0



ОДИН УСТАНОВЩИК НА ТРОИХ Ярлыки Никита / Некит / Лиза — по 1500
непересекающихся запросов. Если у атрибута выбрано «другое» — подтип вводится
вручную. Пустая карточка в режиме 1/0 получает 0 автоматически.



ПРИЛОЖЕНИЕ · УМНЫЙ ПОИСК

MVP умного поиска на C++/Qt


КИЛЛЕР-ФИЧА Ранжирование каталога опирается только на извлечённые факты — бренд, категорию, модель и атрибуты, — а не на сырой текст запроса. Движок на C++ отвечает за 1–2 миллисекунды.



ПРИЛОЖЕНИЕ · ПОСТАВКА

Статистика движка и установщики

КАК РАЗДАЁМ Оба приложения — нативный C++/Qt, собираются CMake и пакуются в установщики Inno Setup с брендингом M.Видео: по 17 МБ вместо 500 МБ у прежней Python-сборки.



- 1 Умный поиск.** Один установщик MVideo_SmartSearch_Setup: движок, словари и каталог внутри.
- 2 Разметка.** Один установщик MVideo_Labeling_Setup на всю команду: три ярлыка — Никита, Некит, Лиза — каждый открывает свой набор из 1500 запросов.
- 3 Настройки.** В обоих приложениях есть страница настроек; в поиске — переключатель тёмной темы.
- 4 Разметка сохраняется в JSONL** рядом с приложением, папка открывается одной кнопкой.

ПЛАН · ДАЛЬШЕ

Следующие шаги

Модели

- 1 Переобучить CRF на разметке с тегом MODEL и свериться с золотой выборкой.
- 2 Классификаторы бренда и категории на кликах, очищенных моделью соответствия.
- 3 Типизатор атрибутов: цепь, затем лёгкий классификатор с контекстом категории для омонимов.

Данные и продукт

- 4 Команда размечает первую волну: 3×1500 запросов и пары для модели соответствия.
- 5 Собранную золотую разметку — в честную оценку каскада.
- 6 Умный поиск: реранжирование с описанием карточки, больше статистики в интерфейсе.

ЦЕЛЬ К ЗАЩИТЕ Рабочий каскад с покрытием сложных случаев и честные метрики на ручной золотой разметке, а не самопроверка словаря.

Спасибо!

MVP собран: предобработка, тег MODEL, каскад моделей и два приложения. Дальше — золотая разметка и качество.

Команда:

Новицкий Никита · @n.novitskiy

Борисов Никита · @n.borisov

Засухина Елизавета · @e.zasukhina

Олейников Александр · @a.oleynikov