

ДЕНЬ 03 · БУТКЕМП М.ВИДЕО · NLP / SEARCH

Глубокий EDA и первый MVP

Предобработка, тег MODEL, разбор схем разметки, рабочий каскад моделей и два готовых приложения: умный поиск и разметка для команды.

Умный поиск · Понимание запроса · MVP

ДЕНЬ 03 · ИТОГИ

Что собрали ко Дню 3

КОРОТКО За день прошли путь от анализа данных до работающего продукта: единая предобработка, новый тег MODEL, каскад из трёх обученных моделей и два настольных приложения.

**Предобработка**

чистка, расклейка

склеек, словарь

моделей на 6120 фраз

**Схемы разметки**

разобрали IO, BIO,

BILOU — храним

списки имен на BIO

**Модели MVP**

классификатор

бренда, CRF,

марковский типизатор


**Приложения**

умный поиск +

разметка для

команды (2 сборки)

С чем работаем: масштаб и длины




ВЫВОД Запросы очень короткие: половина — 2 токена, 99% укладываются в 7. Это задача понимания запроса, а не разбора длинного документа.

- 1 30,99 млн кликов, 1,18 млн карточек. В семпле 200 тысяч строк — 49 тысяч уникальных запросов и 3,1 тысячи брендов.
- 2 Длина в токенах: медиана 2, у 90% — до 4, у 99% — до 7. В символах: 17 и 31.
- 3 Медианная цена клика — 16 165 ₽, пропусков в ключевых полях нет. Короткие запросы — значит

ГЛУБОКИЙ EDA · БРЕНДЫ


73% брендов нет в тексте запроса



ГЛАВНОЕ ЧИСЛО Лишь в 27% кликов бренд написан в самом запросе. В остальных 73% бренд известен только из кликнутой карточки — словарём его не достать.

- 1 Пользователь пишет «айфон 15» — слова «Apple» нет, но купить он хочет именно Apple. Поэтому нужен классификатор бренда по всему запросу.
- 2 17% запросов кликают по двум и более брендам — берём самый частый бренд с весом по позиции клика.
- 3 Там, где словарь нашёл бренд в тексте, он

Слабая разметка: покрытие и границы



КАК ЧИТАТЬ Слабая разметка — это автоматические теги от словарей и правил. Она бесплатная, но шумная: на ней учим, а проверяем на ручной.

- 1 Хотя бы одну сущность получают 79,8% запросов: бренд — у 46%, категория — у 59%, атрибуты — только у 7%.
- 2 У 27% запросов есть продолжение сущности (теги I) — значит нужны именно границы спанов, а не классификация всего запроса.
- 3 Регулярки по атрибутам покрывают всего 3% запросов — атрибуты одним правилом не закрыть, нужен типизатор поверх найденного спана

Единый слой очистки запроса

Шесть шагов очистки

Шаг	Что делает
Базовая чистка	убирает мусорные пробелы, ё → е
Расклейка	«128гб» → «128 гб»
Сепараторы	«g-pro» → «g pro»
Нормализация	единый ключ для словарей
Защита брендов	«Красный Октябрь» — не цвет
Подсказки	спаны моделей поверх разметки

Зачем один общий слой

- 1 Раньше каждый ноутбук чистил запрос по-своему — результаты не сходились. Теперь очистка одна на всех.
- 2 Регистр сохраняем там, где он несёт смысл: «красный» — это цвет, а «Красный Октябрь» — бренд конфет.
- 3 Модуль отдаёт и чистый текст, и подсказки: где в запросе модель, а где защищённый бренд.

ЭФФЕКТ Спан модели появляется у 18% запросов, склейки чинятся у 11%, а каждый четвёртый «пустой» хвост после бренда оживает.

ПРЕДОБРАБОТКА · ПРИМЕР

Живой пример: запрос до и после

ИСХОДНЫЙ ЗАПРОС «Наушники Logitech G-Pro X SE 128гб» — так пишет реальный пользователь: дефисы, склейки, смесь языков.

Шаг 1 · расклейка и сепараторы

наушники logitech g pro x se 128 гб

«G-Pro» распался в «g pro», «128гб» — в «128 гб». Теперь словари смогут найти каждую часть.

Шаг 2 · разметка со словарями и подсказками

наушники · КАТЕГОРИЯ

logitech · БРЕНД

g pro x se · МОДЕЛЬ

128 гб · АТРИБУТ

«g pro x se» поймал словарь моделей (собрали его майнингом — следующие слайды), «128 гб» — регулярка памяти.

ПРЕДОБРАБОТКА · ИЗМЕРЕНИЕ

Что даёт предобработка на семпле



КАК МЕРИЛИ Взяли 12 000 уникальных запросов и прогнали через пайплайн дважды: со словарём моделей и без него.

- 1 18% запросов получают спан модели — примерно каждый пятый.
- 2 11% содержат склейку вида «128гб», которую чинит расклейка.
- 3 24% полностью пустых хвостов после бренда получают тег модели после наложения подсказок.
- 4 Защита брендов и заглавных букв срабатывает у 4,5% — редко, но именно она спасает «Красный Октябрь» от проглатывания в конец

ТЕГ MODEL · ПРОБЛЕМА

Хвост после бренда теряется



ПРОБЛЕМА После бренда часто идёт название линейки — «dyson v15», «galaxy s24». При слабой разметке эти слова остаются без тега, и CRF не может их выучить.

- 1 Из 15 тысяч запросов бренд есть у 7046. Почти у половины из них (46%) после бренда остался неразмеченный латинский хвост.
- 2 Типичная длина хвоста — два токена: «zenbook a16», «ipad air».
- 3 Это не атрибут — нет числа с единицей измерения. Нужен отдельный тег MODEL и

ТЕГ MODEL · ПРИМЕРЫ

Как выглядят потерянные хвосты

ДО СЛОВАРЯ Серые слова — то, что разметка не смогла объяснить. Именно они и есть модели.

До: хвост без тега

пылесос dyson v15
телефон samsung galaxy s24
asus zenbook a16
apple ipad air

После: словарь линеек подключён

пылесос dyson v15 · МОДЕЛЬ
телефон samsung galaxy s24 · МОДЕЛЬ
asus zenbook a16 · МОДЕЛЬ
apple ipad air · МОДЕЛЬ

ЧТО ИЗМЕНИЛОСЬ Хвост после бренда перестал быть «мусором» — теперь это полноценный факт «модель», по которому можно искать и ранжировать.

Майнинг словаря: пример «g pro»

ИДЕЯ Названия кликнутых карточек уже содержат модели. Находим в названии бренд — и всё, что идёт после него, считаем кандидатом в модели.

Название карточки → кандидаты

Наушники Logitech G PRO X SE Black


После бренда снимаем от одного до четырёх коротких токенов и получаем цепочку кандидатов:

Кандидат	Сколько раз встретился
g	213
g pro	87

Почему порог — 6 раз

- 1 Фраза попадает в словарь, только если встретилась в названиях карточек **минимум 6 раз**. «g pro» видели 87 раз — берём. «g pro x se black» — два раза, это случайный хвост с цветом, отсекаем.
- 2 Порог ниже (2) — словарь раздувается до 7215 фраз и тащит мусор. Порог выше (20) — остаётся 335 фраз и теряются редкие линейки.
- 3 Шесть — золотая середина: 1512 фраз,

Выбор порога: размер словаря против покрытия




КАК ЧИТАТЬ ГРАФИК Чёрная кривая — размер словаря, красная — доля хвостов, которые он покрывает. Пунктир — наш выбор.

- 1 Из 47 тысяч названий карточек намайнили 8540 сырых кандидатов: galaxy, iphone, watch, redmi и другие.
- 2 Кривые расходятся плавно, «локтя» нет — выбрали порог 6 как компромисс между размером и покрытием.
- 3 Дополнительные фильтры: голые числа не берём; фразы из одного токена — только коды вида «v15», «a305», «ps5»

ТЕГ MODEL · РЕЗУЛЬТАТ

До и после подключения словаря



ВЫВОД Словарь линеек включает класс MODEL: было 0 запросов с тегом — стало 1573. Потерянных хвостов стало меньше на четверть.

- 1 Латинские хвосты без тега: 3262 → 2502, минус 23%.
- 2 Проверили качество словаря вручную: 96,6% фраз — настоящие линейки, остальное — длинные артикулы и аксессуары, их вычистим.
- 3 Оставшиеся хвосты словарём не закрыть — это кандидаты на ручную разметку, для неё мы сделали приложение (покажем дальше).

РАЗМЕТКА · СХЕМЫ

Какие бывают схемы токен-разметки

КОНТЕКСТ Задача NER — найти спаны сущностей. Но модели классифицируют токены, поэтому спаны кодируют в токен-схему. Разные схемы — разные способы обозначить границы.

Схема	Теги	Суть
IO	I, O	самое простое, но две соседние сущности сливаются
BIO (IOB)	B, I, O	B отмечает начало — границы видны; стандарт CoNLL
IOE	I, O, E	то же самое, только отмечается конец, а не начало
BILOU	B, I, L, O, U	добавляются теги конца (L) и одиночного слова (U)
BIES	B, I, E, S, O	максимум классов — сильнее дисбаланс, учить труднее

Общая беда всех токен-схем: вложенные сущности не выразить — «адрес» нельзя разбить на город, улицу и дом

РАЗМЕТКА · ВЫБОР

Храним спаны, учим на BIO

ВЫВОД Спаны — универсальный формат хранения и оценки: любой модельный ответ приводится к ним. BIO — формат обучения. Держим оба.

Почему именно BIO

- 1 Классы — полные теги (B-BRAND, I-ATTR и так далее). Буквы B, I, O лишь кодируют границы.
- 2 У 27% запросов сущности длиннее одного токена. Схема IO склеила бы соседние сущности в одну, BIO их разделяет.
- 3 BIOU на коротких запросах даёт больше классов без выигрыша — дисбаланс растёт, качество нет.
- 4 Наши теги: BRAND, MODEL, CATEGORY, ATTR (с приставками B и I) плюс O.

Пример BIO-разметки

ноутбук **B-CATEGORY**

asus **B-BRAND**

zenbook **B-MODEL**

16 **B-ATTR**

гб **I-ATTR**

РАЗМЕТКА · ИСТОЧНИКИ

Два сигнала сливаются в одну разметку

ИДЕЯ Текст запроса и поведение пользователей — независимые источники правды. Их слияние даёт разметку, которой не было ни в одном из них по отдельности.




Факт	Откуда сигнал
Бренд в тексте	словарь по запросу
Скрытый бренд	только клики
Категория	словарь + клики
Модель	майнинг названий карточек
Атрибуты	регулярки по тексту

Пример: в запросе «айфон 15 про» словарь бренда

Гибридный каскад: что уже собрано

КАК УСТРОЕНО Каждый слой закрывает слабость предыдущего: правила — мгновенные, CRF понимает морфологию, классификатор достаёт скрытый бренд, цепь определяет тип атрибута. На выходе — факты за десятки миллисекунд.



Путь запроса от строки до выдачи

ЗАЧЕМ Извлечь факты — только середина пути: дальше нормализация, каталог и ранжирование.



Шаг	Пример
Нормализация	«16гб», «16 gb», «16 ГБ» — всё превращается в одно значение: 16 ГБ
Каталог	категория «ноутбук» находит узел «Ноутбуки и планшеты»
Ранжирование	карточки с брендом asus и памятью 16 ГБ идут наверх

MVP · КЛАССИФИКАТОР БРЕНДА

Бренд, когда его нет в тексте

НА ЧЁМ УЧИЛИ Обучающее множество собрано автоматически из кликов: запрос → самый частый бренд среди кликнувших карточек. Ни одной ручной метки.

Как устроен

- 1 Признаки — кусочки слов по 3–5 букв. Поэтому «айфон», «afon» и «iphone» выглядят похоже, опечатки не страшны.
- 2 18 914 обучающих запросов, сорок самых частых брендов.
- 3 Включается только когда словарь не нашёл бренд в тексте — как запасной вариант.

Быстрый тест

Точность (топ-40 брендов)	0,80
Средний F1 по классам	0,77
Обучающих запросов	18 914

айфон 15 про макс > Apple

редми ноут 13 > Xiaomi

CRF на слабой разметке, путь к золотой

ЧЕСТНОСТЬ Числа ниже — проверка «повторила ли модель правила», поэтому они завышены. Настоящую оценку даст только ручная золотая разметка.

Быстрый тест на выборке

Точность по токенам	0,91
F1 по сущностям	0,875
F1 бренды	0,95
F1 категории	0,82
F1 атрибуты	0,85

Слабая и золотая разметка

- 1 Слабая — автоматическая, от словарей и правил: много и бесплатно, но с шумом. На ней учим.
- 2 Золотая — ручная, 300–1000 запросов со спанами моделей. На ней честно меряем.
- 3 Если и учить, и проверять на одних и тех же автоматических метках — модель просто копирует правила, а числа льстят. Отложенная золотая выборка решает это.
- 4 Далее: переобучить CRF на разметке с тегом MODEL

и сравнить её с золотой

MVP · МАРКОВСКИЕ ЦЕПИ

Тип атрибута: «16 гб» — это память



КАК РАБОТАЕТ CRF находит спан атрибута, а марковская цепь по паре соседних токенов говорит его тип: после «256» почти всегда идёт «гб» — значит это память.

16 гб



память

55 дюймов



диагональ

2 кг



вес

wi-fi




связь

1 Это таблица частот, выученная из данных, — никакой нейросети. Ответ за доли миллисекунды.

2 Точность против правил-учителя — 0,62; в 36% случаев цепь честно говорит «не знаю», но почти

MVP · ГРАНИЦЫ МЕТОДА

Где цепь бессильна: голое число



ПРЕДЕЛ Число без единицы измерения многозначно: «5» встречается в десяти разных типах атрибутов. Пара токенов тут не помогает — нужен контекст категории.

- 1 Нашли 27 «числовых омонимов»: «5» и «12» бывают десятью разными атрибутами, «1» — восемью.
- 2 План усложнения по лестнице: правила → цепь → лёгкий классификатор с учётом категории → нейросеть только для омонимов.
- 3 Берём самый дешёвый слой, который держит время ответа. — и усложняем только там, где он

РАЗМЕТКА · СООТВЕТСТВИЕ 1/0

Чистим шумные клики моделью

ЗАЧЕМ Клик — шумный сигнал: пользователь искал айфон, а кликнул чехол. Такие пары портят обучение. Убираем их бинарной моделью «соответствует или нет».



Пример пары

ноутбук asus 16 + ASUS VivoBook 16 > 1

ноутбук asus 16 + Чехол для MacBook > 0


1 Признаки: похожесть текста запроса и названия, совпадение бренда, позиция клика.

2 Дальше дорабатываем только пары, где модель сомневается — так разметка окупается быстрее.

РАЗМЕТКА · СТРАТЕГИЯ

Данные и стратегия разметки

ПРИНЦИП Разметку проектируем, а не «докупаем объёмом»: размечаем в первую очередь то, на чём модель ошибается или сомневается.



ПРИЛОЖЕНИЕ · РАЗМЕТКА

Готово: приложение для разметки команды

ТРИ СБОРКИ Для Никиты, Некита и Лизы — по 1500 уникальных запросов, наборы не пересекаются. Клавиши В, I, O + выбор категории, история с правкой, прогресс и автосохранение в файл.

М.Видео · Разметка · Никита

ВЮ-разметкаMatch 1/0

Запрос: 1 из 1500 · размечено 0

Открыть папку с разметкой

0 / 1500

Запрос: «Игры pc5»

Игрыpc5

1 · BRAND2 · MODEL3 · CATEGORY4 · ATTR5 · GENRE

подтип ATTR: —

В — начало сущностиI — продолжениеO — не сущность

← НазадСохранить и дальше →

История (двойной клик — редактировать):

М.Видео · Разметка · Никита

ВЮ-разметкаMatch 1/0

Пара 1 из 1500 · размечено 0

Открыть папку с разметкой

0 / 1500

Запрос пользователя:
«Игры pc5»

Карточка товара:
PSS игра WB Games Metro: Exodus - Complete Edition
Бренд: WB Games · Цена: 1 840 ₽

1 — соответствует0 — не соответствует

← НазадПропустить →

История (двойной клик — редактировать):



ПРИЛОЖЕНИЕ · УМНЫЙ ПОИСК

Готово: MVP умного поиска

КИЛЛЕР-ФИЧА Ранжирование каталога опирается только на извлечённые факты — бренд, категорию, модель и атрибуты, — а не на сырой текст запроса.

Умный поиск · извлечение фактов18.1 мс

ноутбук asus zenbook 16 r6 серыйНайти

Извлечённые факты

бренд - ASUSкатегория - ноутбукатрибут - 16 r6атрибут - серый

Показать JSON и статистику

Товары по фактам (12) — ранжирование только по извлечённым фактам

1

Ноутбук ASUS Vivobook 17 X1704VA-AU1078 Intel Core 5 120U, 16 Гб, 512 Гб, Intel UHD Graphics, 17.3" 1920x1080 60Гц IPS, noOS (90NB13X1-M00L70)
ASUS - 87 959 ₽ · счёт 6.379 (бренд - категория - атрибут 16 r6)

2

Ноутбук ASUS TUF Gaming F16 FX607VU-RL061 16" (1920x1200) IPS, Core 5 210H, 16Гб DDR5, 512Гб SSD, RTX 4050 6Гб, Win11 Pro, серый (90N80N06-M002T0_Win11P)
ASUS - 96 884 ₽ · счёт 6.355 (бренд - категория - атрибут серый)

3

Ноутбук ASUS UX3407NA-QD158W 14" OLED/Snapdragon X2 Elite X2E 88 100 /32Гб/1Тб/Windows 11 Home/Серый
ASUS - 161 019 ₽ · счёт 6.355 (бренд - категория - атрибут серый)

4

Ноутбук Asus E1504FA-L1834
ASUS - 52 000 ₽ · счёт 5.803 (бренд - категория)

5

Ноутбук ASUS Vivobook 16 M1807HA
ASUS - 100 507 ₽ · счёт 5.539 (бренд - категория)

Умный поиск · извлечение фактов18.1 мс

ноутбук asus zenbook 16 r6 серыйНайти

Извлечённые факты

бренд - ASUSкатегория - ноутбукатрибут - 16 r6атрибут - серый

Показать JSON и статистику

```
{
  "query": "ноутбук asus zenbook 16 r6 серый",
  "entities": {
    {
      "text": "ноутбук",
      "label": "CATEGORY",
      "span": {
        "start": 0,
        "end": 1
      }
    },
    {
      "text": "asus",
      "label": "BRAND",
      "span": {
        "start": 2,
        "end": 3
      }
    }
  }
}
```

Товары по фактам (12) — ранжирование только по извлечённым фактам

1

Ноутбук ASUS Vivobook 17 X1704VA-AU1078 Intel Core 5 120U, 16 Гб, 512 Гб, Intel UHD Graphics, 17.3" 1920x1080 60Гц IPS, noOS (90NB13X1-M00L70)
ASUS - 87 959 ₽ · счёт 6.379 (бренд - категория - атрибут 16 r6)

2

Ноутбук ASUS TUF Gaming F16 FX607VU-RL061 16" (1920x1200) IPS, Core 5 210H, 16Гб DDR5, 512Гб SSD, RTX 4050 6Гб, Win11 Pro, серый (90N80N06-M002T0_Win11P)
ASUS - 96 884 ₽ · счёт 6.355 (бренд - категория - атрибут серый)

ПЛАН · ДАЛЬШЕ

Следующие шаги

Модели

- 1 Переобучить CRF на разметке с тегом MODEL и свериться с золотой выборкой.
- 2 Классификаторы бренда и категории на кликах, очищенных моделью соответствия.
- 3 Типизатор атрибутов: цепь, затем лёгкий классификатор с контекстом категории для омонимов.

Данные и продукт

- 4 Команда размечает первую волну: 3×1500 запросов и пары для модели соответствия.
- 5 Собранную золотую разметку — в честную оценку каскада.
- 6 Умный поиск: реранжирование с описанием карточки, больше статистики в интерфейсе.

ЦЕЛЬ К ЗАЩИТЕ Рабочий каскад с покрытием сложных случаев и честные метрики на ручной золотой разметке, а не самопроверка словаря.

Спасибо!

MVP собран: предобработка, тег MODEL, каскад моделей и два приложения. Дальше — золотая разметка и качество.

Команда:

Новицкий Никита · @n.novitskiy

Борисов Никита · @n.borisov

Засухина Елизавета · @e.zasukhina

Олейников Александр · @a.oleynikov