

БУТКЕМП М.ВИДЕО · NLP / SEARCH · ИТОГИ

Умный поиск: от данных до каскада

Query Understanding для М.Видео: EDA → MVP-каскад → SpellFix, GLiNER и честные метрики на золоте.

Итоговая презентация · Дни 02–04

СТРУКТУРА

О чём расскажем

01**Задача и данные**

масштаб, короткие запросы,
главный инсайт EDA

02**Пайплайн**

гибридный каскад
и что реально в проде

03**День 04**

SpellFix, журнал,
GLiNER, joint study

04**Метрики**

gold vs silver,
что работает на опечатках

05**Честно**

ограничения и
следующие шаги

06**Демо**

поиск и разметка
как продукт

ЗАДАЧА

Не «ещё один NER», а понимание запроса

ЦЕЛЬ Из короткой строки пользователя достать факты (бренд, категория, модель, атрибуты) и отдать их поиску / фильтрам — быстро, интерпретируемо, с запасными слоями.

Почему сложно

- 1 Запросы короткие: 1–3 токена, часто без бренда.
- 2 Опечатки, смесь кириллицы/латиницы, транслит.
- 3 Клики шумные: кликнули не то, что написали.
- 4 Одна модель на всём не закрывает SLA и edge-cases.

Наш ответ

- 1 **Словари и правила** — мгновенный слой.
- 2 **CRF** — морфология и контекст токенов.
- 3 **Классификаторы** — скрытый бренд и тип ATTR.
- 4 **SpellFix** — чиним текст до моделей.
- 5 **GLiNER** — гибкий хвост (пока эксперимент).

ДЕНЬ 02 · ДАННЫЕ

С чем работаем

ВЫВОД Данных достаточно и для словарей, и для обучения: узкое место не объём, а качество меток.

30.99 млн

кликов: запрос → SKU

1.79 млн

уникальных запросов

1.18 млн

карточек title + description

333 тыс

уникальных SKU в кликах

7 150

брендов

546 тыс

офферов в YML-каталоге


Пример строки клика

query: «galaxy s25»
sku: Смартфон Samsung Galaxy
S25 FE 8/256GB Black
brand: Samsung · price: 50 703
₽ · position: 2

ДЕНЬ 02 · КЛЮЧЕВОЙ ИНСАЙТ

73% брендов нет в тексте запроса

Где находится бренд: запрос vs карточка клика



ВЫВОД Только в **27%** кликов бренд написан в запросе. Поэтому в каскаде нужен не только словарь, но и классификатор бренда.

- 1 Голова трафика — категорийные запросы без бренда.
- 2 Клики живут в топе выдачи — шум смешивается с сигналом.
- 3 Отсюда архитектура: правила → NER → запасной бренд-слой.

ПАЙПЛАЙН · ПРОД

Гибридный каскад, который работает сейчас

В ПРОДЕ SpellFix → / → CRF → brand_clf → ATTR. Тот же каскад в Qt .exe, FastAPI и CLI. GLiNER обучен и измерен, в сервис пока не вшит.



- 1 Каждый слой закрывает слабость предыдущего: словарь — мгновенно, CRF — морфологию, brand_clf — скрытый бренд.
- 2 Одинаковый SpellFix и при сборке silver, и в бою — модель не видит «грязный» текст только в проде.
- 3 На выходе — структурированные факты (entities + attributes), а не «чёрный ящик».

ДЕНЬ 03 · MVP

Что собрали как продукт

Предобработка

единый слой очистки
запроса до моделей

Тег MODEL

майнинг словаря
моделей из кликов

Каскад моделей

CRF + brand_clf
+ типизатор ATTR

Два приложения

умный поиск
и разметка BIO

Brand classifier

67 классов, в т.ч. NO_BRAND / UNKNOWN · macro-F1
≈ **0,94** на silver-val · лучше отказать, чем
подставить ложный бренд.

CRF + ATTR

CRF на слабой BIO-разметке · марковский
типизатор атрибутов рядом с правилами · петля
качества через ручную разметку.

HTTP API и CLI для того же каскада

ОДИН EXTRACTOR Настольный Qt-движок, FastAPI и CLI ходят в одну логику фактов: SpellFix → правила → CRF → brand/ATTR. Меняем слой один раз — проверяем тремя способами.

FastAPI (src/service)

- 1 POST /extract — JSON фактов для интеграции.
- 2 POST /extract/debug — BIO-пайплайны для лаборатории.
- 3 GET /health — готовность моделей и словарей.
- 4 Веб-UI из web/ на том же порту.

CLI + журнал

- 1 `python -m src.cli.cli " " " " — быстрый smoke-тест каскада.`
- 2 Режим `-i / --demo` для демо без UI.
- 3 `artifacts/history/` — снимки метрик CRF/brand/ATTR и broken queries (не теряются в git-диффах).

ДЕНЬ 04 · НОВШЕСТВА

Что изменилось после MVP

КОРОТКО Закрыли шум на входе, завели человекочитаемый журнал экспериментов, прогнали GLiNER как хвост и впервые измерили весь каскад на трёх типах данных.

SpellFix v2

гомоглифы, fuzzy,
алиасы транслита

CRF rebuild

пересборка silver
+ gold microF1 ↑

Журнал

artifacts/history
метрики + кейсы

GLiNER + joint

один silver,
метрика пайплайн

SPELLFIX V2

Опечатки, гомоглифы и транслит — до модели

Три механики

Механика	Пример
Fuzzy + клавиатура	«16гь» → «16 гб», «телфон» → «телефон»
Гомоглифы	кир./лат. двойники: с/с, а/а, е/е
Алиасы	«сони» → «sony», «ксяоми» → «xiaomi»

Эффект на CRF

SpellFix тронул **767 / 5000** silver-запросов до обучения.

Gold micro-F1: **0,582 → 0,594**.

Сильнее всего вырос ATTR (+0,07) — единицы с опечаткой больше не ломают учителя.

Вывод Одна функция чинит текст и при сборке обучающих данных, и в бою — без отдельного «продакшен-режима».

ДЕНЬ 04 · ЖУРНАЛ

Честные кейсы и история экспериментов

SpellFix справляется

телефон 16 гь > телефон 16 гб

планше txiaomi > планшет xiaomi

ноутбук asus 16гь > ноутбук asus 16 гб

Пока нет


моильник 16 гб — слишком далёкая порча (3 буквы),
вне fuzzy

HISTORY artifacts/history/ —
снимки метрик CRF / brand / ATTR
+ broken_queries.md. Git хранит код;
сюда пишем «что поменяли и что
получили».

НЕ СПРЯТАЛИ На «sony ps5» NER
ок, но category_clf иногда путает
PlayStation с феном/смартфоном —
отдельный баг, не SpellFix.

GLINER · ZERO-SHOT

Что даёт модель без дообучения

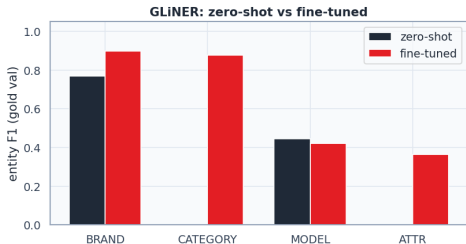


МОДЕЛЬ urchade/gliner_multi-v2.1 — мультязычный чекпоинт. Роль — гибкий хвост, не замена CRF.

- 1 Лучшая схема промпта — английские лейблы: micro-F1 **0,35** на gold.
- 2 BRAND находится и без обучения ($F1 \approx 0,79$).
- 3 CATEGORY / ATTR почти пустые — домену нужны примеры.

GLINER · FINE-TUNE

После обучения на gold + silver




ВЫВОД micro-F1 **0,39** → **0,74**: CATEGORY подтянулась с 0 до 0,88 — модель увидела домен.

- 1 Порог откалиброван отдельно ($\approx 0,35$): default 0,5 резал верные, но неуверенные спаны.
- 2 ATTR остаётся самым слабым ($F1 \approx 0,36$) — мало и шумно в gold.
- 3 В прод не подключён: сначала гейт и latency-бюджет.

JOINT STUDY

Один silver — честное сравнение каскада

ИДЕЯ CRF и GLiNER на **одном** silver; gold — held-out. Стадии: rules → +CRF → +GLiNER.



- 1 На **broken** главный прирост — CRF: **0,58** → **0,85**.
- 2 На **gold** GLiNER сверху: **0,61** → **0,64**.
- 3 На шуме «слепой» хвост **портит** precision (0,85→0,80).
- 4 Silver-val $\approx 1,0$ — самосогласие teacher, не истина.

ВЫВОД GLiNER звать только когда rules+CRF ничего не нашли — не для безусловного дозаполнения.

МЕТРИКИ · СВОДКА

Честные ориентиры на одной странице

Что	было	стало	где смотреть
CRF gold micro-F1	0,582	0,594	после SpellFix
Brand clf macro-F1	—	0,94	silver-val
Каскад gold (rules+CRF+GL)	0,604	0,640	joint study
Каскад broken (rules+CRF)	0,578	0,846	устойчивость к шуму
GLiNER FT gold	0,39	0,74	изолированный трек

Главное правило: silver-val красивый, но завышен. Решения принимаем по gold и по broken-кейсам.

ЧЕСТНО · ДАЛЬШЕ

Что знаем и куда идём

Ограничения

- 1 Gold маленький (181) — хвостовые теги шумные.
- 2 GLiNER ещё не в `extractor.py`.
- 3 `category_clf` ошибается на редких категориях.
- 4 Жёсткие порчи вроде «моильник» SpellFix не ловит.

Следующие шаги

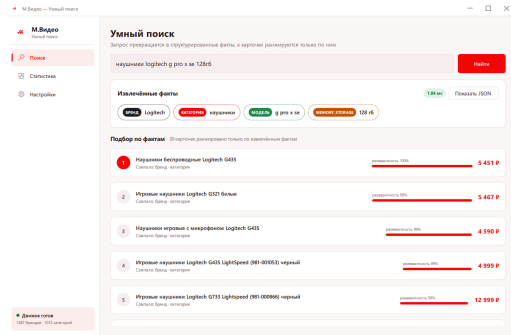
- 1 Расширить и дочистить `gold` → CRF v2.
- 2 Вшить GLiNER с гейтом (только пустые ответы).
- 3 Починить `category_clf` на консолях/редких категориях.
- 4 Пополнять `spell_aliases.txt` из разметки.

ВЫВОД Пайплайн уже измерен на трёх типах данных — дальше усиливаем то, что реально работает, а не гонимся за красивым числом на `silver`.




ПРОДУКТ

Два приложения команды



Умный поиск

Qt: факты чипами + выдача по извлечённым полям



Разметка

BIO-мастер (B/I/O) + типы сущностей для золота

Спасибо!

Вопросы по пайплайну, SpellFix, GLiNER и метрикам — welcome.

Команда:

Новицкий Никита · @n.novitskiy

Борисов Никита · @n.borisov

Засухина Елизавета · @e.zasukhina

Олейников Александр · @a.oleynikov